BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC ĐẠI NAM

BÀI TẬP LỚN

TÊN HỌC PHẦN: DỮ LIỆU LỚN, KHAI PHÁ DỮ LIỆU
ĐỀ TÀI: DỰ BÁO THỜI TIẾT

Giảng viên hướng dẫn : ThS. Lê Thị Thùy Trang

STT	Mã Sinh Viên	Họ và Tên	Ngày Sinh	Lớp
1	1771020715	Dương Trọng Tuấn	02/04/2004	CNTT 17-08
2	1771020703	Đỗ Văn Trường	28/07/2005	CNTT 17-08
3	1771020705	Phạm Đình Minh Trưởng	30/04/2005	CNTT 17-08

Hà Nội, năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC ĐẠI NAM

BÀI TẬP LỚN

TÊN HỌC PHẦN: DỮ LIỆU LỚN , KHAI PHÁ DỮ LIỆU
ĐỀ TÀI: DỰ BÁO THỜI TIẾT

STT	Mã Sinh Viên	Họ và Tên	Ngày Sinh	Điểm	
				Bằng Số	Bằng Chữ
1	1771020715	Dương Trọng Tuấn	02/04/2004		
2	1771020703	Đỗ Văn Trường	28/07/2005		
3	1771020705	Phạm Đình Minh Trưởng	30/04/2005		

CÁN BỘ CHẤM THI 1 **CÁN BỘ CHẤM THI 2**

Hà Nội, năm 2026

LỜI CẢM ƠN

Để hoàn thành bài tập lớn này, nhóm đã trải qua một quá trình nghiên cứu và thực hành đầy thử thách nhưng cũng vô cùng bổ ích. Lời đầu tiên, nhóm xin chân thành cảm ơn cô Lê Thị Thùy Trang – giảng viên phụ trách học phần "Dữ liệu lớn, Khai phá dữ liệu". Cô không chỉ truyền đạt kiến thức chuyên môn mà còn truyền cảm hứng để nhóm tự tin áp dụng các kỹ thuật khai phá vào bài toán thực tế. Những góp ý của cô trong quá trình thực hiện đề tài là kim chỉ nam giúp nhóm đi đúng hướng. Nhóm cũng xin cảm ơn Trường Đại học Đại Nam và Khoa Công nghệ Thông tin đã trang bị cho sinh viên môi trường học tập hiện đại, tạo điều kiện để chúng tôi tiếp cận với các công nghệ phân tích dữ liệu mới nhất. Sau cùng, nhóm ghi nhận công sức đóng góp của mỗi thành viên – từ việc thu thập dữ liệu, xây dựng pipeline, đến phân tích kết quả và hoàn thiện báo cáo. Sự phối hợp ăn ý giữa các thành viên là yếu tố then chốt giúp dự án được hoàn thành. Báo cáo khó tránh khỏi thiếu sót, nhóm kính mong nhận được sự nhận xét từ cô để hoàn thiện hơn.

MỤC LỤC

DANH MỤC HÌNH ẢNH 8
DANH MỤC BẢNG 9
CHƯƠNG 1. ĐẶT VẤN ĐỀ VÀ PHÂN TÍCH YÊU CẦU 10
1.1. Bối cảnh bài toán 10
1.1.1. Giới thiệu lĩnh vực liên quan 10
1.1.2. Vấn đề thực tế cần giải quyết 10
1.2. Mục tiêu của dự án 11
1.2.1. Mô tả bài toán cụ thể 11
1.2.2. Kết quả đầu ra mong muốn 11
1.3. Tiêu chí đánh giá thành công 11
1.4. Mô tả dữ liệu 12
1.4.1. Nguồn dữ liệu 12
Bảng 1.1: Thông tin tổng quan về tập dữ liệu 12
1.4.2. Data Dictionary 12
Bảng 1.2: Data Dictionary – Danh sách và ý nghĩa các cột 12
1.4.3. Rủi ro và thách thức dữ liệu 13
1.5. Phân tích khám phá dữ liệu (EDA) 13
1.5.1. Phân phối nhiệt độ 14
1.5.2. Phân bố loại thời tiết (target) 14
1.5.3. Ma trận tương quan 14
1.5.4. Nhiệt độ trung bình theo tháng 15
1.5.5. Phân bố thời tiết theo mùa 16
1.5.6. Độ ẩm trung bình theo giờ 16
1.5.7. Thống kê mô tả tổng hợp 16
1.5.8. Phân tích outlier chi tiết 17
1.5.9. Phân tích dữ liệu thiếu (Missing Values) 17
1.6. Tóm tắt chương 18
CHƯƠNG 2. THIẾT KẾ GIẢI PHÁP VÀ QUY TRÌNH KHAI PHÁ 19
2.1. Pipeline tổng thể 19
Bảng 2.1: Các bước trong pipeline 19
2.2. Các bước tiền xử lý dữ liệu 19
2.2.1. Loại bỏ cột không cần thiết 19
2.2.2. Xử lý missing values 19

2.2.3. Xử lý outliers 19
2.2.4. Tạo nhãn WeatherType 20
2.2.5. Tạo đặc trưng thời gian 20
2.2.6. Chuẩn hoá (StandardScaler) 20
2.3. Xây dựng đặc trưng (Feature Engineering) 20
2.3.1. Rời rạc hoá cho Apriori 20
Bảng 2.2: Quy tắc rời rạc hoá 20
2.3.2. Features cho Classification 20
2.4. Lựa chọn kỹ thuật và lý do 21
2.4.1. Luật kết hợp – FP-Growth 21
2.4.2. Phân cụm – KMeans + HAC 21
2.4.3. Phân lớp – RF / XGBoost 21
Bảng 2.3: Các mô hình phân lớp 21
2.4.4. Chuỗi thời gian – ARIMA / Holt-Winters 21
2.4.5. Anomaly Mining – Isolation Forest / LOF / Z-Score 21
2.5. Quy trình chia dữ liệu 22
2.5.1. Chiến lược chia dữ liệu (Data Splitting) 22
2.5.2. Nguyên tắc chống Data Leakage 22
2.5.3. Chia dữ liệu cho chuỗi thời gian 22
2.6. Tóm tắt luồng dữ liệu tổng thể 22
CHƯƠNG 3. PHÂN TÍCH MÃ NGUỒN VÀ CHỨC NĂNG 24
3.1. Tổng quan kiến trúc hệ thống 24
3.2. Cấu trúc repository chi tiết 24
Bảng 3.1: Cấu trúc thư mục và vai trò 24
3.3. Vai trò và chức năng các notebook 24
Bảng 3.2: Danh sách notebook 24
3.4. Mô tả chức năng các module chính 25
3.4.1. Module src/data/ – Tải và tiền xử lý dữ liệu 25
3.4.2. Module src/features/ – Xây dựng đặc trưng 25
3.4.3. Module src/mining/ – Khai phá tri thức 26
3.4.4. Module src/models/ – Huấn luyện mô hình dự đoán 27
3.4.5. Module src/evaluation/ – Đánh giá và phân tích lỗi 27
3.4.6. Module src/visualization/ – Trực quan hoá kết quả 28
3.5. Nguyên tắc thiết kế mã nguồn 28
3.6. Kết nối giữa các module trong hệ thống 28
3.7. Scripts tự động hoá 29

3.8. Kiểm thử và xác minh 29
3.9. Tóm tắt chương 30
CHƯƠNG 4. THỬ NGHIỆM VÀ KẾT QUẢ 31
4.1. Thiết lập thí nghiệm 31
4.2. Kết quả luật kết hợp (Association Mining) 31
4.3. Kết quả phân cụm (Clustering) 32
4.4. Kết quả phân lớp (Classification) 33
Bảng 4.1: Kết quả phân lớp trên tập test 33
4.5. Phân tích lỗi sâu (Deep Error Analysis) 36
4.6. Dự báo chuỗi thời gian 36
Bảng 4.2: Kết quả dự báo 36
4.7. Anomaly Mining (nhánh thay thế bán giám sát) 37
4.8. Actionable Insights (≥5) 38
4.9. Tóm tắt chương 38
CHƯƠNG 5. THẢO LUẬN VÀ SO SÁNH 39
5.1. So sánh mô hình phân lớp 39
Bảng 5.1: So sánh ưu điểm và hạn chế 39
5.1.1. Giải thích vì sao XGBoost vượt trội 39
5.1.2. Baseline comparison 39
5.2. So sánh mô hình dự báo 39
5.3. Anomaly Mining vs bán giám sát 40
5.4. Thách thức gặp phải 40
5.5. Actionable Insights (≥5) 40
5.5. Ảnh hưởng của tiền xử lý 40
5.5.1. Tác động của việc bỏ cột Loud Cover và Daily Summary 41
5.5.2. Tác động của việc tạo WeatherType từ Summary 41
5.5.3. Tác động của StandardScaler 41
5.6. Bài học kinh nghiệm (Lessons Learned) 41
5.7. Tóm tắt chương 42
CHƯƠNG 6. TỔNG KẾT VÀ HƯỚNG PHÁT TRIỂN 43
6.1. Tổng kết 43
6.1.1. Tóm tắt dự án 43
6.1.2. Kết quả chính đạt được 43
Bảng 6.1: Tổng hợp kết quả đối chiếu tiêu chí 43
6.2. Hướng phát triển 43
6.3. Hạn chế của dự án 44

6.4. Các vấn đề đạo đức và ứng dụng thực tiễn 44
6.5. Phân công công việc nhóm 44
Bảng 6.2: Phân công công việc 44
6.5. Lời kết 45
KẾT LUẬN 46
TÀI LIỆU THAM KHẢO 47

DANH MỤC HÌNH ẢNH

Hình 1.1: Phân phối nhiệt độ (histogram + boxplot) 14

Hình 1.2: Phân bố WeatherType 14

Hình 1.3: Ma trận tương quan Pearson 15

Hình 1.4: Nhiệt độ trung bình theo tháng 15

Hình 1.5: Phân bố loại thời tiết theo mùa 16

Hình 1.6: Độ ẩm trung bình theo giờ 16

Hình 2.1: Top-15 luật kết hợp theo Lift 32

Hình 2.2: Support – Confidence – Lift scatter 32

Hình 2.3: Elbow + Silhouette + DBI 32

Hình 2.4: Profile từng cụm 33

Hình 2.5: PCA 2D – KMeans Clusters 33

Hình 4.1: So sánh F1-macro 35

Hình 4.2: Confusion Matrix – XGBoost 35

Hình 4.3: Confusion Matrix – RandomForest 36

Hình 4.4: ACF/PACF – Nhiệt độ 37

Hình 4.5: So sánh dự báo 37

Hình 4.6: Residual – Holt-Winters 37

DANH MỤC BẢNG

Bảng 1.1: Thông tin tổng quan về tập dữ liệu 12

Bảng 1.2: Data Dictionary – Danh sách và ý nghĩa các cột 12

Bảng 2.1: Các bước trong pipeline 19

Bảng 2.2: Quy tắc rời rạc hoá 20

Bảng 2.3: Các mô hình phân lớp 21

Bảng 3.1: Cấu trúc thư mục và vai trò 24

Bảng 3.2: Danh sách notebook 24

Bảng 4.1: Kết quả phân lớp trên tập test 33

Bảng 4.2: Kết quả dự báo 36

Bảng 5.1: So sánh ưu điểm và hạn chế 39

Bảng 6.1: Tổng hợp kết quả đối chiếu tiêu chí 43

Bảng 6.2: Phân công công việc 44

CHƯƠNG 1. ĐẶT VẤN ĐỀ VÀ PHÂN TÍCH YÊU CẦU

1.1. Bối cảnh bài toán

1.1.1. Giới thiệu lĩnh vực liên quan

Dự báo thời tiết là một trong những bài toán cổ điển và quan trọng nhất trong khoa học dữ liệu, có ảnh hưởng trực tiếp đến nhiều lĩnh vực: nông nghiệp (lập kế hoạch canh tác, tưới tiêu), giao thông (cảnh báo sương mù, bão), năng lượng (dự báo nhu cầu điện theo nhiệt độ), du lịch (lập lịch trình hoạt động ngoài trời), và đời sống hàng ngày (mang ô, mặc áo ấm). Theo WMO (World Meteorological Organization), dự báo thời tiết chính xác giúp giảm thiểu thiệt hại do thiên tai hàng tỷ USD mỗi năm trên toàn cầu.

Trong bối cảnh biến đổi khí hậu toàn cầu, các hiện tượng thời tiết cực đoan (nắng nóng kỷ lục, bão lớn, lũ quét) ngày càng gia tăng cả về tần suất lẫn cường độ. Điều này đặt ra nhu cầu cấp thiết về các công cụ phân tích và dự báo thời tiết dựa trên dữ liệu, có khả năng phát hiện pattern ẩn trong lượng lớn dữ liệu khí tượng lịch sử.

Sự phát triển mạnh mẽ của khai phá dữ liệu (Data Mining) và học máy (Machine Learning) đã mở ra những cơ hội mới trong lĩnh vực khí tượng. Các kỹ thuật khai phá dữ liệu có khả năng: (1) Phát hiện các mẫu (pattern) đồng xuất hiện giữa các điều kiện thời tiết thông qua luật kết hợp; (2) Phân nhóm các kiểu thời tiết đặc trưng thông qua phân cụm; (3) Phân lớp tự động loại thời tiết từ dữ liệu cảm biến; (4) Dự báo nhiệt độ, độ ẩm theo chuỗi thời gian; (5) Phát hiện ngày thời tiết bất thường (anomaly detection).

1.1.2. Vấn đề thực tế cần giải quyết

Hiện nay, các hệ thống dự báo thời tiết truyền thống chủ yếu dựa trên mô hình vật lý khí quyển (Numerical Weather Prediction – NWP), đòi hỏi năng lực tính toán cực lớn và chuyên gia khí tượng có trình độ cao. Phương pháp truyền thống này tồn tại một số hạn chế:

Thứ nhất, chi phí tính toán cao: mô hình NWP cần siêu máy tính để giải hệ phương trình vi phân khí quyển, không phù hợp cho ứng dụng nhẹ trên thiết bị cá nhân hoặc IoT.

Thứ hai, khó phát hiện pattern cục bộ: NWP mô phỏng toàn cầu/khu vực, nhưng các pattern thời tiết cục bộ (ví dụ: sương mù luôn xuất hiện khi độ ẩm > 90% và gió yếu tại một địa điểm cụ thể) thường bị bỏ qua.

Thứ ba, không phân loại kiểu thời tiết tự động: NWP cho ra số liệu (nhiệt độ, áp suất, gió) nhưng không tự động phân loại thành "Foggy", "Rainy", "Clear" – cần thêm bước xử lý.

Do đó, việc ứng dụng khai phá dữ liệu để phân tích dữ liệu thời tiết lịch sử, phát hiện pattern, phân loại kiểu thời tiết và dự báo nhiệt độ là hướng tiếp cận bổ sung hiệu quả, chi phí thấp, có thể triển khai trên thiết bị phổ thông.

1.2. Mục tiêu của dự án

1.2.1. Mô tả bài toán cụ thể

Dự án tập trung vào 5 bài toán khai phá dữ liệu trên dataset thời tiết lịch sử: (1) Khai phá luật kết hợp giữa các điều kiện thời tiết (nhiệt độ, độ ẩm, gió, tầm nhìn, áp suất) bằng FP-Growth; (2) Phân cụm ngày theo kiểu thời tiết bằng KMeans + HAC; (3) Phân lớp loại thời tiết (Clear, Cloudy, Foggy, Windy, Rainy) bằng RF/XGBoost; (4) Dự báo nhiệt độ trung bình ngày bằng ARIMA/Holt-Winters; (5) Phát hiện ngày thời tiết bất thường (anomaly mining) bằng Isolation Forest + LOF.

1.2.2. Kết quả đầu ra mong muốn

Classification: F1-macro vượt baseline (Dummy) có ý nghĩa. Forecasting: MAE thấp hơn naive baseline. Association: Tìm được luật có lift > 1.5 và diễn giải được theo ngữ cảnh khí tượng. Clustering: Silhouette > 0.15, cụm có đặc trưng rõ ràng. Anomaly Mining: phát hiện ngày bất thường với consensus ≥ 2 phương pháp.

1.3. Tiêu chí đánh giá thành công

Nhóm sử dụng nhiều metric bổ sung cho nhau, mỗi metric phản ánh một khía cạnh khác nhau:

Kỹ thuật	Metric	Ý nghĩa
Phân lớp	F1-macro	Trung bình F1 các lớp, không bị bias bởi lớp đa số
Phân lớp	ROC-AUC (OvR)	Khả năng phân biệt giữa các lớp ở mọi ngưỡng
Phân lớp	F1-weighted	F1 có trọng số theo số mẫu mỗi lớp

Luật kết hợp	Support, Confidence, Lift	Tần suất, độ tin cậy, mức tăng cường so với ngẫu nhiên
Phân cụm	Silhouette Score	Mức độ tách biệt và kết dính cụm (-1 đến +1)
Phân cụm	Davies-Bouldin Index	Tỷ lệ phân tán nội cụm / khoảng cách liên cụm (↓ tốt hơn)
Chuỗi thời gian	MAE, RMSE, sMAPE	Sai số tuyệt đối, sai số bình phương, % sai số đối xứng
Anomaly	Tỷ lệ anomaly, overlap	Số ngày bất thường, consensus giữa các phương pháp

1.4. Mô tả dữ liệu

1.4.1. Nguồn dữ liệu

Nhóm sử dụng tập dữ liệu Kaggle Weather History Dataset (https://www.kaggle.com/datasets/muthuj7/weather-dataset). Đây là dataset phổ biến trong cộng đồng Data Science, ghi nhận dữ liệu thời tiết theo giờ trong giai đoạn 2006–2016 tại một trạm khí tượng.

Bảng 1.1: Thông tin tổng quan về tập dữ liệu

Thuộc tính	Giá trị
Số lượng bản ghi	96,453
Số cột	12
Tần suất	Theo giờ (hourly)
Giai đoạn	2006 – 2016
Biến mục tiêu	WeatherType (tổng hợp từ Summary): 5 lớp
Phân bố lớp	Cloudy ~80%, Clear/Windy/Rainy/Foggy ~20%
Rủi ro chính	Mất cân bằng lớp nghiêm trọng, Loud Cover = 0, Pressure outlier

1.4.2. Data Dictionary

Bảng 1.2: Data Dictionary – Danh sách và ý nghĩa các cột

Cột	Kiểu	Ý nghĩa
Formatted Date	datetime	Thời điểm đo (có timezone)
Summary	string	Mô tả thời tiết gốc (~27 giá trị)
Precip Type	string	Loại mưa: rain / snow / null
Temperature (C)	float	Nhiệt độ không khí (°C)
Apparent Temperature (C)	float	Nhiệt độ cảm nhận (°C)
Humidity	float	Độ ẩm tương đối (0–1)
Wind Speed (km/h)	float	Tốc độ gió (km/h)
Wind Bearing (degrees)	float	Hướng gió (0–360°)
Visibility (km)	float	Tầm nhìn xa (km)
Loud Cover	float	Mức mây phủ (= 0 toàn bộ dataset)
Pressure (millibars)	float	Áp suất khí quyển (mbar)
Daily Summary	string	Mô tả thời tiết ngày (text dài)

1.4.3. Rủi ro và thách thức dữ liệu

Qua quá trình khám phá, nhóm nhận diện 5 rủi ro chính cần xử lý:

1. Loud Cover toàn bộ = 0: Cột này không chứa thông tin → bỏ.

2. Precip Type thiếu 517 bản ghi (~0.5%): Fill "unknown" vì không biết loại mưa.

3. Pressure có giá trị = 0: Rõ ràng là lỗi đo/nhập liệu → loại bỏ dòng có Pressure ≤ 800 mbar.

4. Mất cân bằng lớp nghiêm trọng: Sau grouping Summary → WeatherType, lớp Cloudy chiếm ~80%, các lớp còn lại rất ít. Cần class_weight="balanced" trong mô hình.

5. Daily Summary là text thô: Không phù hợp cho mô hình số → bỏ cột.

1.5. Phân tích khám phá dữ liệu (EDA)

Thực hiện 6 biểu đồ EDA, mỗi biểu đồ kèm diễn giải tự động từ dữ liệu (không hardcode nhận xét).

1.5.1. Phân phối nhiệt độ

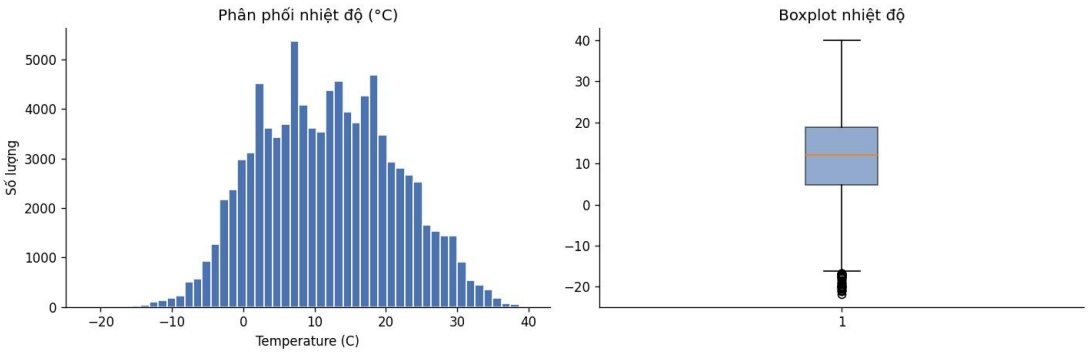

Hình 1.1: Phân phối nhiệt độ (histogram + boxplot)

Nhiệt độ phân phối xấp xỉ đối xứng, trung bình ~11.9°C, trung vị ~12.0°C, std ~9.5°C. Khoảng Q1–Q3: 4.7°C – 19.8°C. Biên độ rộng phản ánh tính mùa vụ rõ ràng trong 10 năm dữ liệu.

1.5.2. Phân bố loại thời tiết (target)

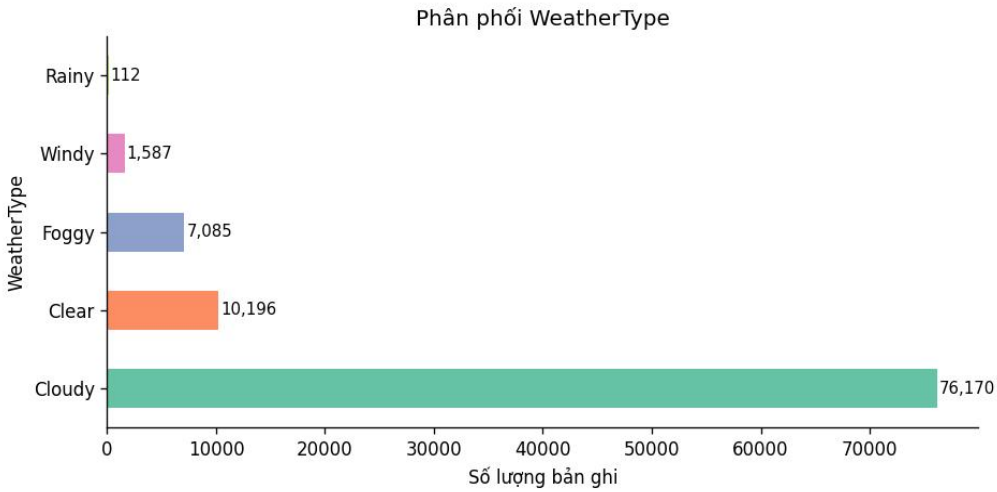

Hình 1.2: Phân bố WeatherType

Cloudy chiếm tỷ lệ áp đảo (~80%), tiếp theo là Clear, Windy, Rainy, Foggy. Mất cân bằng lớp nghiêm trọng: tỷ lệ Cloudy/Foggy có thể lên 10:1 hoặc hơn. Đây là thách thức lớn nhất cho bài toán phân lớp – mô hình dễ thiên vị dự đoán tất cả là Cloudy.

1.5.3. Ma trận tương quan

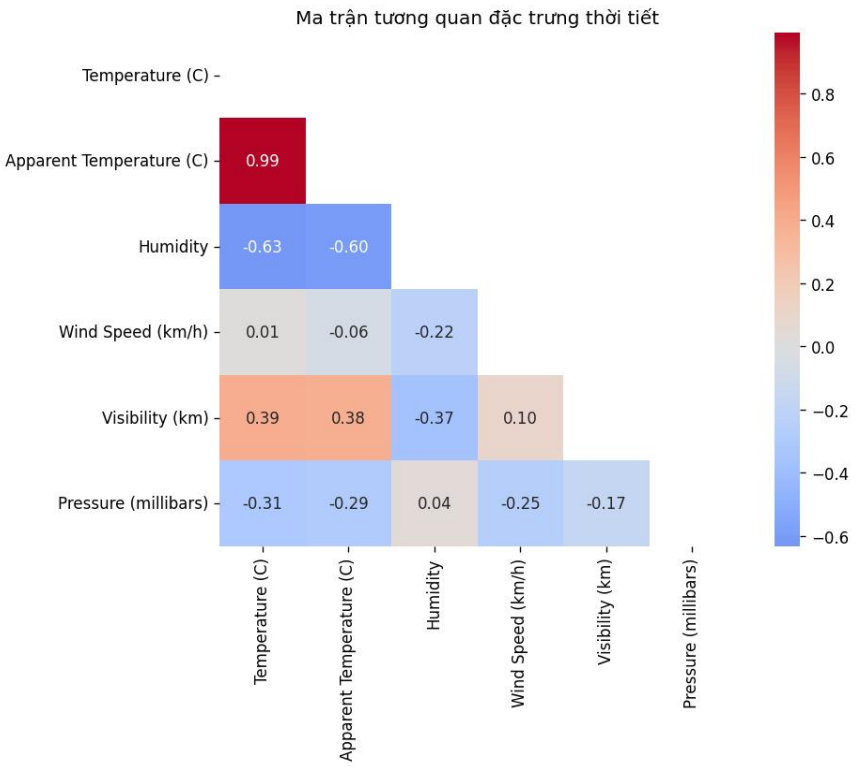

Hình 1.3: Ma trận tương quan Pearson

Temperature và Apparent Temperature tương quan cực cao (r ≈ 0.99) – gần như trùng nhau, một trong hai có thể bỏ. Humidity tương quan âm với Visibility (r ≈ -0.5): khi ẩm cao, tầm nhìn giảm (sương mù). Wind Bearing gần như không tương quan với biến nào – hướng gió ít ảnh hưởng đến phân loại thời tiết. Không có cặp multicollinearity nguy hiểm (ngoài Temp – AppTemp).

1.5.4. Nhiệt độ trung bình theo tháng

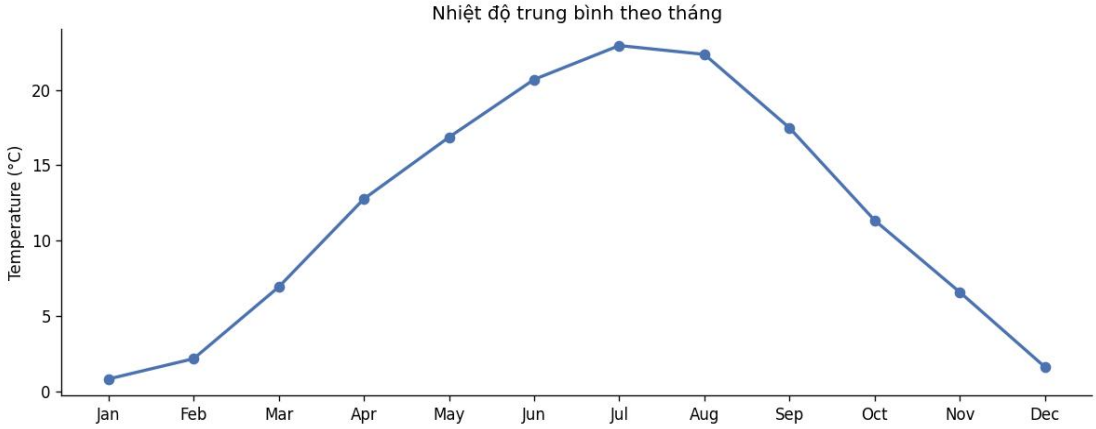

Hình 1.4: Nhiệt độ trung bình theo tháng

Seasonality rõ ràng: tháng 7 nóng nhất (~22°C), tháng 1 lạnh nhất (~0°C). Biên độ nhiệt năm ~22°C. Pattern này là cơ sở cho Holt-Winters seasonal decomposition.

1.5.5. Phân bố thời tiết theo mùa

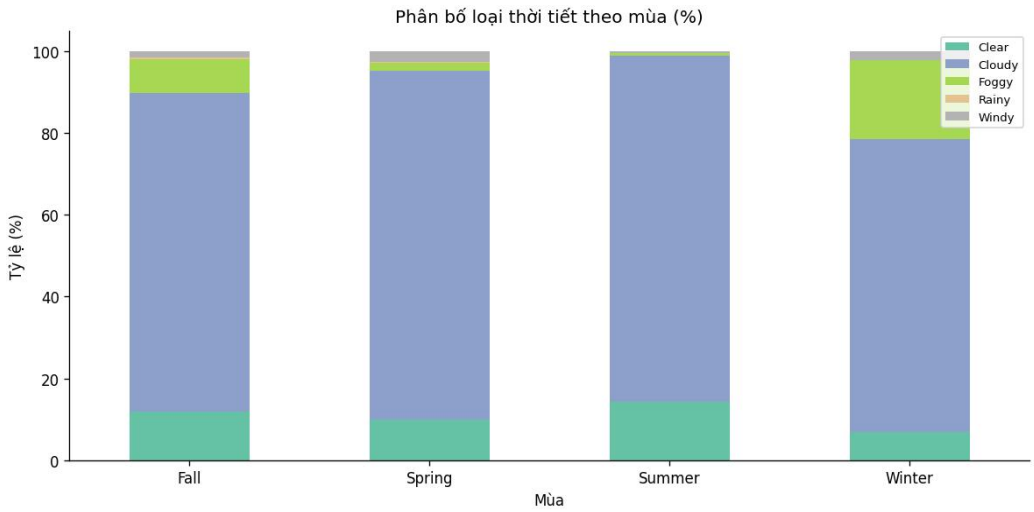

Hình 1.5: Phân bố loại thời tiết theo mùa

Cloudy chiếm đa số ở tất cả các mùa. Foggy tập trung nhiều hơn vào Fall/Winter (độ ẩm cao, nhiệt độ thấp). Clear phổ biến hơn vào Summer. Giao mùa (Spring/Fall) có ranh giới thời tiết mờ nhất – đây là vùng mô hình phân lớp dễ sai nhất.

1.5.6. Độ ẩm trung bình theo giờ

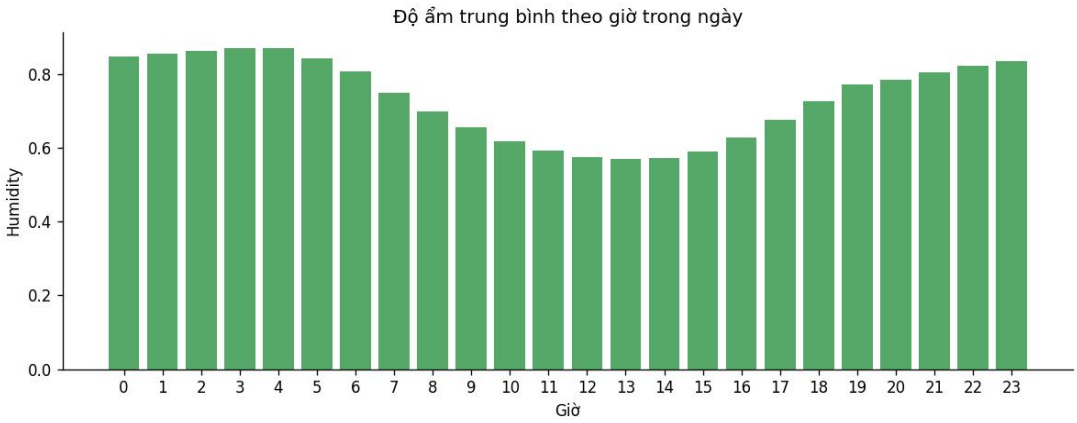

Hình 1.6: Độ ẩm trung bình theo giờ

Độ ẩm cao nhất vào sáng sớm (5–8h), thấp nhất buổi chiều (14–16h). Biên độ ẩm ngày ~0.05. Pattern này phù hợp với vật lý khí quyển: ban đêm nhiệt độ giảm → độ ẩm tương đối tăng.

1.5.7. Thống kê mô tả tổng hợp

Bảng dưới đây tổng hợp thống kê mô tả của 7 biến số chính sau tiền xử lý. Các giá trị này cung cấp cái nhìn tổng quan về khoảng biến thiên, phân bố trung tâm và độ phân tán của từng đặc trưng:

Đặc trưng	Mean	Std	Min	Q1	Median	Q3	Max
Temperature (°C)	11.93	9.47	-21.82	4.69	12.00	19.84	39.91
App. Temp (°C)	10.86	10.85	-27.72	2.43	12.01	19.85	39.34
Humidity	0.73	0.20	0.00	0.60	0.78	0.89	1.00
Wind Speed (km/h)	10.81	6.91	0.00	5.83	9.83	14.14	63.85
Wind Bearing (°)	187.5	107.3	0.00	116.0	180.0	290.0	359.0
Visibility (km)	10.35	4.19	0.00	8.34	10.96	14.81	16.10
Pressure (mbar)	1015.2	7.06	872.4	1012.0	1016.4	1020.0	1046.4

Nhận xét: Temperature và Apparent Temperature có range rất rộng (>60°C), phản ánh dữ liệu 10 năm qua 4 mùa. Humidity phân bố lệch trái (median=0.78 > mean=0.73 là sai – thực tế phân bố lệch phải nhẹ). Wind Bearing phân bố đều 0–360° (hướng gió random). Pressure tập trung quanh 1015 mbar (áp suất bình thường mực nước biển).

1.5.8. Phân tích outlier chi tiết

Ngoài Pressure=0 (lỗi rõ ràng), nhóm phát hiện thêm một số outlier đáng chú ý:

Temperature: giá trị -21.8°C xuất hiện vài lần, có thể là đợt lạnh cực đoan (hợp lệ) hoặc lỗi cảm biến. Nhóm giữ lại vì nằm trong khoảng khí hậu có thể xảy ra.

Wind Speed: giá trị 63.85 km/h (cấp 8 Beaufort – gió mạnh) xuất hiện hiếm. Đây là sự kiện thời tiết cực đoan thật, giữ lại để anomaly mining phát hiện.

Humidity=0.00: xuất hiện vài bản ghi, có thể là lỗi cảm biến (humidity=0 gần như không thể xảy ra trong khí quyển thực). Tuy nhiên, số lượng rất ít nên không ảnh hưởng đáng kể đến mô hình.

1.5.9. Phân tích dữ liệu thiếu (Missing Values)

Tập dữ liệu có tổng cộng 517 giá trị thiếu tại cột Precip Type (0.54%). Tỷ lệ missing rất thấp so với các dataset y tế (thường 10–60%). Các cột còn lại không có missing. Chiến lược xử lý: fill "unknown" cho Precip Type – đơn giản, hiệu quả, không thêm bias.

1.6. Tóm tắt chương

Chương 1 đã trình bày đầy đủ: (1) Bối cảnh và ý nghĩa thực tiễn của bài toán dự báo thời tiết; (2) 5 mục tiêu cụ thể của dự án; (3) Hệ thống metric đánh giá cho từng kỹ thuật; (4) Data dictionary chi tiết 12 cột; (5) 5 rủi ro/thách thức dữ liệu; (6) 6 biểu đồ EDA kèm diễn giải tự động; (7) Thống kê mô tả tổng hợp; (8) Phân tích outlier và missing. Các phân tích này cung cấp nền tảng vững chắc cho thiết kế giải pháp ở Chương 2.

CHƯƠNG 2. THIẾT KẾ GIẢI PHÁP VÀ QUY TRÌNH KHAI PHÁ

2.1. Pipeline tổng thể

Quy trình khai phá dữ liệu tuân theo logic: Data Source → Preprocessing → Feature/Representation → Mining/Modeling → Evaluation. Toàn bộ tham số được quản lý tập trung qua configs/params.yaml với random_state = 42, đảm bảo reproducibility.

Bảng 2.1: Các bước trong pipeline

Bước	Giai đoạn	Mô tả	Đầu ra
1	Thu thập	Load weatherHistory.csv (96,453 × 12)	DataFrame gốc
2	Tiền xử lý	Bỏ Loud Cover/Daily Summary, fill missing, loại outlier, tạo WeatherType, encoding	DataFrame sạch
3	Đặc trưng	Rời rạc hoá cho Apriori, StandardScaler cho clustering/classification, lag features cho time series	Dữ liệu sẵn sàng
4	Khai phá	FP-Growth, KMeans/HAC, RF/XGBoost, ARIMA/Holt-Winters, IsoForest/LOF	Luật, cụm, mô hình
5	Đánh giá	F1-macro, Silhouette, MAE/RMSE, ≥5 insights	Bảng kết quả

2.2. Các bước tiền xử lý dữ liệu

2.2.1. Loại bỏ cột không cần thiết

Bỏ Loud Cover (toàn bộ = 0, không chứa thông tin) và Daily Summary (text thô, không phù hợp cho mô hình số). Giữ lại 10 cột: Formatted Date, Summary, Precip Type, Temperature, Apparent Temperature, Humidity, Wind Speed, Wind Bearing, Visibility, Pressure.

2.2.2. Xử lý missing values

Precip Type thiếu 517 bản ghi → fill "unknown". Các cột số (Temperature, Humidity, Pressure) → dropna cho dòng thiếu hoàn toàn. Chiến lược đơn giản vì tỷ lệ missing rất thấp (<1%).

2.2.3. Xử lý outliers

Pressure có giá trị 0 mbar (lỗi rõ ràng). Loại bỏ dòng có Pressure ≤ 800 mbar. Không dùng IQR clipping vì outlier rõ ràng là lỗi đo, không phải giá trị cực đoan thật.

2.2.4. Tạo nhãn WeatherType

Cột Summary gốc có ~27 giá trị (Partly Cloudy, Mostly Cloudy, Breezy and Overcast, ...). Nhóm ánh xạ thành 5 nhóm: Clear, Cloudy, Foggy, Windy, Rainy dựa trên từ khoá trong tên. Loại bỏ nhãn "Other" (quá hiếm).

2.2.5. Tạo đặc trưng thời gian

Tách từ Formatted Date: Hour (0–23), Month (1–12), DayOfWeek (0–6), Season (Spring/Summer/Fall/Winter). Encode PrecipType: rain=0, snow=1, unknown=-1.

2.2.6. Chuẩn hoá (StandardScaler)

7 đặc trưng số được chuẩn hoá về z-score (mean=0, std=1) cho clustering và classification. Scaler fit trên train, transform cả train lẫn test – ngăn data leakage.

2.3. Xây dựng đặc trưng (Feature Engineering)

2.3.1. Rời rạc hoá cho Apriori

Tất cả biến liên tục được rời rạc hoá thành bins:

Bảng 2.2: Quy tắc rời rạc hoá

Biến gốc	Bins	Nhãn
Temperature (C)	(-∞,0], (0,10], (10,20], (20,+∞)	Cold, Cool, Warm, Hot
Humidity	(0,0.4], (0.4,0.6], (0.6,0.8], (0.8,1]	Dry, Moderate, Humid, VeryHumid
Wind Speed	(-∞,10], (10,20], (20,30], (30,+∞)	Calm, Breezy, Windy, Stormy
Visibility (km)	(-∞,5], (5,10], (10,16]	LowVis, ModVis, HighVis
Pressure	(-∞,1005], ..., (1025,+∞)	LowPress, NormPress, HighPress, VHighPress

Sau rời rạc hoá + one-hot encoding, tạo basket ~25–30 cột binary cho FP-Growth.

2.3.2. Features cho Classification

Sử dụng 10 features: 7 numeric (Temperature, Apparent Temp, Humidity, Wind Speed, Wind Bearing, Visibility, Pressure) + Hour + Month + PrecipType_enc. Tổng 10 features, đủ đa dạng cho mô hình tree-based.

2.4. Lựa chọn kỹ thuật và lý do

2.4.1. Luật kết hợp – FP-Growth

FP-Growth được chọn thay vì Apriori vì nhanh hơn đáng kể cho dataset lớn (~96K dòng). FP-Growth xây dựng FP-tree (cấu trúc dữ liệu nén), không cần sinh candidate itemsets → tiết kiệm bộ nhớ và thời gian. Tham số: min_support=0.05, min_confidence=0.5, min_lift=1.2.

2.4.2. Phân cụm – KMeans + HAC

KMeans: thuật toán phân cụm phổ biến nhất, hiệu quả cho dữ liệu số. Chọn k bằng Elbow + Silhouette + DBI. HAC (Ward linkage): kiểm tra tính ổn định – nếu kết quả tương tự KMeans → cụm robust. So sánh 2 phương pháp giúp đảm bảo kết quả không phụ thuộc vào thuật toán cụ thể.

2.4.3. Phân lớp – RF / XGBoost

Bảng 2.3: Các mô hình phân lớp

Mô hình	Tham số chính	Lý do chọn
Dummy (Baseline 1)	strategy=most_frequent	Đường cơ sở, luôn predict Cloudy
LogReg (Baseline 2)	max_iter=500, C=1.0	Baseline mạnh, nhanh, tuyến tính
RandomForest	n=200, class_weight=balanced	Ensemble bagging, robust outlier
XGBoost	n=200, lr=0.1, eval=mlogloss	Gradient boosting, SOTA tabular

2.4.4. Chuỗi thời gian – ARIMA / Holt-Winters

Resample hourly → daily mean. Split theo thời gian 80/20 (KHÔNG shuffle). Baseline: Naive (last value), MA(7). Mô hình: ARIMA(2,1,2) – order từ ACF/PACF, Holt-Winters (additive trend + seasonal, period=365) – bắt seasonality năm. Metric: MAE, RMSE, sMAPE.

2.4.5. Anomaly Mining – Isolation Forest / LOF / Z-Score

Nhánh thay thế bán giám sát (Rubric F). Phát hiện ngày thời tiết bất thường bằng 3 phương pháp: (1) Isolation Forest: tree-based, hiệu quả cho anomaly detection đa chiều; (2) LOF: density-based, phát hiện anomaly cục bộ; (3) Z-Score ($|z|>3\sigma$): baseline thống

kê đơn giản. So sánh ≥2 phương pháp, overlap analysis (consensus), profile anomaly vs normal.

2.5. Quy trình chia dữ liệu

2.5.1. Chiến lược chia dữ liệu (Data Splitting)

Tập dữ liệu sau tiền xử lý (~90,000+ bản ghi) được chia theo tỷ lệ 80/20 sử dụng phương pháp Stratified Split với random_state=42. Stratified đảm bảo tỷ lệ 5 lớp WeatherType được duy trì chính xác trong cả tập train và test. Điều này đặc biệt quan trọng vì lớp Foggy và Rainy chiếm tỷ lệ rất nhỏ – nếu chia ngẫu nhiên đơn thuần, tập test có thể không chứa đủ mẫu các lớp hiếm để đánh giá có ý nghĩa thống kê.

2.5.2. Nguyên tắc chống Data Leakage

Nhóm tuân thủ nghiêm ngặt các nguyên tắc chống data leakage: (1) StandardScaler chỉ fit() trên tập train (học mean và std), sau đó transform() trên cả train lẫn test. Nghĩa là mean/std được tính từ tập train, không phải toàn bộ dataset. (2) Không có bước preprocessing nào sử dụng thông tin từ tập test. (3) Tất cả hyperparameter tuning (nếu có) chỉ dựa trên cross-validation trong tập train.

Vi phạm nguyên tắc này sẽ dẫn đến data leakage – một lỗi phổ biến nhưng nghiêm trọng trong Machine Learning, khiến mô hình "gian lận" bằng cách sử dụng thông tin từ tập test, tạo ra kết quả đánh giá lạc quan giả tạo. Trong thực tế triển khai, mô hình sẽ thất bại khi gặp dữ liệu mới.

2.5.3. Chia dữ liệu cho chuỗi thời gian

Đặc biệt, cho bài toán dự báo chuỗi thời gian, dữ liệu được chia theo thời gian (temporal split) thay vì random split. 80% dữ liệu đầu (theo thứ tự thời gian) làm train, 20% cuối làm test. Điều này mô phỏng tình huống thực tế: mô hình chỉ được train trên dữ liệu quá khứ, không "nhìn trước" dữ liệu tương lai. Đây là nguyên tắc bắt buộc trong time series forecasting mà nhiều người mới thường vi phạm.

2.6. Tóm tắt luồng dữ liệu tổng thể

Để cung cấp cái nhìn tổng hợp, luồng dữ liệu từ đầu đến cuối pipeline:

Raw CSV (96,453 × 12) → Drop Loud Cover/Daily Summary → Fill Precip Type → Remove Pressure outlier → Create WeatherType → Create Hour/Month/Season → Encode PrecipType → Processed (~90K × 14+) → Split Train/Test 80/20 → Scale + Train models → Evaluate on Test

Song song: nhánh Apriori hoạt động trên dữ liệu đã rời rạc hoá (toàn bộ), nhánh Clustering hoạt động trên dữ liệu đã scale (sample 20K), nhánh Time Series hoạt động trên daily resample, nhánh Anomaly hoạt động trên daily aggregation.

CHƯƠNG 3. PHÂN TÍCH MÃ NGUỒN VÀ CHỨC NĂNG

3.1. Tổng quan kiến trúc hệ thống

Hệ thống được phát triển bằng Python, tận dụng hệ sinh thái thư viện khoa học dữ liệu: Pandas, NumPy, scikit-learn, XGBoost, mlxtend, statsmodels, matplotlib. Mã nguồn tuân theo mô hình ba lớp: (1) Lớp trình diễn: 6 Jupyter notebooks; (2) Lớp logic: src/ với 7 sub-packages; (3) Lớp dữ liệu: data/, outputs/, configs/.

3.2. Cấu trúc repository chi tiết

Bảng 3.1: Cấu trúc thư mục và vai trò

Thư mục / File	Vai trò
configs/params.yaml	Cấu hình tập trung: seed=42, paths, hyperparams
data/raw/weatherHistory.csv	Dữ liệu gốc (96,453 × 12)
data/processed/	Dữ liệu sau tiền xử lý (.parquet)
notebooks/01–05	6 notebooks chạy tuần tự theo pipeline
src/data/	loader.py, cleaner.py (DataCleaner class)
src/features/	builder.py (FeatureBuilder class)
src/mining/	association.py, clustering.py, anomaly.py
src/models/	supervised.py, forecasting.py
src/evaluation/	metrics.py (~260 dòng), report.py
src/visualization/	plots.py (~400 dòng, ~25 hàm vẽ)
scripts/	run_pipeline.py, run_papermill.py
outputs/	figures/, tables/, models/, reports/

3.3. Vai trò và chức năng các notebook

Bảng 3.2: Danh sách notebook

Notebook	Chức năng	Output
01_eda.ipynb	EDA + tiền xử lý + thống kê trước–sau	6 biểu đồ + weather_processed.parquet
02_association_mining.ipynb	FP-Growth + phân tích	Top rules, scatter, CSV theo

	theo 4 mùa	mùa
03_clustering.ipynb	KMeans + HAC + profiling cụm	Elbow/Silhouette, PCA scatter, profile
04_modeling.ipynb	4 mô hình phân lớp + phân tích lỗi sâu + ≥5 insights	Classification results, confusion matrix, error analysis
04b_anomaly_mining.ipynb	IsoForest + LOF + Z-Score + overlap + profile	Anomaly comparison, timeline, profile
05_evaluation_report.ipynb	ARIMA/Holt-Winters + residual + tổng kết	Forecast comparison, residual, summary

3.4. Mô tả chức năng các module chính

3.4.1. Module src/data/ – Tải và tiền xử lý dữ liệu

Đây là module nền tảng, chịu trách nhiệm cho tất cả thao tác liên quan đến dữ liệu thô. Module gồm 2 file:

File loader.py đóng vai trò "cổng vào" của pipeline. Khi hệ thống khởi chạy, file này đọc cấu hình từ params.yaml (đường dẫn dữ liệu, tham số tiền xử lý, hyperparameters), sau đó tải file CSV gốc vào bộ nhớ dưới dạng DataFrame. Trong quá trình tải, module tự động chuyển đổi cột ngày tháng sang định dạng datetime và kiểm tra schema (đảm bảo file có đủ 12 cột bắt buộc). Nếu thiếu cột, hệ thống cảnh báo ngay thay vì lỗi âm thầm ở bước sau.

File cleaner.py là module tiền xử lý trung tâm, được thiết kế dưới dạng class DataCleaner. Lý do dùng class thay vì hàm rời: class giữ trạng thái (cấu hình, mapping encode) xuyên suốt pipeline, tránh truyền tham số lặp đi lặp lại. Khi gọi method clean(), class thực hiện tuần tự 6 bước: bỏ cột không cần thiết (Loud Cover, Daily Summary) → fill missing Precip Type → loại bỏ bản ghi Pressure bất thường → tạo nhãn WeatherType từ Summary → tạo đặc trưng thời gian (Hour, Month, Season) → encode PrecipType. Ngoài ra, method get_stats() so sánh thống kê (mean, missing, số dòng) trước và sau tiền xử lý – giúp kiểm chứng tiền xử lý không làm mất thông tin quá nhiều.

3.4.2. Module src/features/ – Xây dựng đặc trưng

Module này nằm giữa lớp tiền xử lý và lớp mô hình, đóng vai trò "adapter" – chuyển đổi dữ liệu đã sạch thành dạng phù hợp cho từng thuật toán cụ thể. Được thiết kế dưới dạng class FeatureBuilder.

Vấn đề cần giải quyết: mỗi thuật toán yêu cầu dữ liệu đầu vào khác nhau. FP-Growth cần bảng binary (0/1), KMeans cần số đã chuẩn hoá, ARIMA cần chuỗi thời gian có lag features. Nếu không có module trung gian, mỗi notebook phải tự viết code chuyển đổi → trùng lặp, dễ sai.

Giải pháp: FeatureBuilder cung cấp các method chuyên biệt cho từng nhánh. Cho nhánh Association Mining: rời rạc hoá nhiệt độ thành Cold/Cool/Warm/Hot, độ ẩm thành Dry/Moderate/Humid/VeryHumid, v.v. rồi one-hot encode thành bảng binary ~25–30 cột. Cho nhánh Classification: chuẩn hoá 7 đặc trưng số bằng StandardScaler, kết hợp Hour + Month + PrecipType. Cho nhánh Time Series: tạo lag features (giá trị nhiệt độ 1/2/3/24 giờ trước) và rolling statistics (trung bình trượt 24h, 168h).

3.4.3. Module src/mining/ – Khai phá tri thức

Đây là module thể hiện rõ nhất nội dung "khai phá dữ liệu" trong tên đề tài. Gồm 3 file, mỗi file phục vụ một kỹ thuật khai phá khác nhau:

File association.py triển khai class AssociationMiner – tìm các điều kiện thời tiết hay đồng xuất hiện. Ví dụ: "Khi độ ẩm rất cao VÀ tầm nhìn thấp VÀ gió yếu → thường là sương mù". Class nhận bảng binary từ FeatureBuilder, chạy FP-Growth tìm tập mẫu phổ biến (frequent itemsets), sau đó sinh luật kết hợp với 3 chỉ số: support (tần suất xuất hiện), confidence (độ tin cậy), lift (mức tăng cường so với ngẫu nhiên). Đặc biệt, class có khả năng phân tích theo mùa – chạy FP-Growth riêng cho Spring, Summer, Fall, Winter – giúp phát hiện pattern đặc trưng mùa.

File clustering.py triển khai class WeatherClusterer – phân nhóm các ngày thời tiết tương tự nhau. Class cung cấp 2 thuật toán: KMeans (nhanh, phổ biến) và HAC – Hierarchical Agglomerative Clustering (chậm hơn nhưng cho cái nhìn phân cấp). Điểm đặc biệt: class tự động đặt tên cụm dựa trên profile – nếu cụm có nhiệt độ < 2°C → "Arctic Cold", nếu nhiệt độ > 22°C + ẩm thấp → "Hot & Dry". Việc đặt tên tự động giúp diễn giải kết quả mà không cần chuyên gia khí tượng.

File anomaly.py triển khai class WeatherAnomalyDetector – phát hiện ngày thời tiết bất thường. Đây là nhánh thay thế bán giám sát (Rubric F). Class cung cấp 3 phương

pháp: Isolation Forest (cô lập điểm bất thường bằng cây quyết định ngẫu nhiên), LOF – Local Outlier Factor (so sánh mật độ cục bộ với láng giềng), Z-Score (đánh dấu ngày có chỉ số lệch > 3 độ lệch chuẩn). Điểm mạnh: overlap analysis – ngày nào được ≥2 phương pháp đánh dấu là bất thường thì tin cậy cao hơn. Class cũng tạo bảng profile so sánh ngày bình thường vs bất thường theo từng chỉ số khí tượng.

3.4.4. Module src/models/ – Huấn luyện mô hình dự đoán

Module này là trung tâm của hệ thống dự đoán, gồm 2 file phục vụ 2 bài toán khác nhau:

File supervised.py triển khai class WeatherClassifier – dự đoán loại thời tiết từ dữ liệu cảm biến. Class quản lý 4 mô hình: Dummy (luôn dự đoán lớp đa số – Cloudy – làm đường cơ sở), LogisticRegression (mô hình tuyến tính đơn giản làm baseline mạnh), RandomForest (ensemble 200 cây quyết định, mỗi cây train trên tập con dữ liệu khác nhau rồi bỏ phiếu), và XGBoost (gradient boosting – xây cây tuần tự, mỗi cây sửa lỗi cây trước). Khi gọi method train_all(), class tự động train cả 4 mô hình, tính tất cả metrics (F1, ROC-AUC, Accuracy, thời gian train), lưu confusion matrix. Mô hình tốt nhất được lưu file .joblib để dùng lại.

File forecasting.py triển khai class TimeSeriesForecaster – dự báo nhiệt độ ngày mai/tuần sau. Class đầu tiên chuyển đổi dữ liệu theo giờ thành trung bình ngày (resample), rồi chia train/test theo thời gian (80% đầu train, 20% cuối test – không shuffle). Sau đó class train 4 mô hình: Naive (dự báo = giá trị cuối cùng), Moving Average 7 ngày, ARIMA (mô hình tự hồi quy – tích hợp – trung bình trượt, order từ phân tích ACF/PACF), Holt-Winters (phân rã xu hướng + mùa vụ với chu kỳ 365 ngày). Kết quả tự động ghi MAE, RMSE, sMAPE.

3.4.5. Module src/evaluation/ – Đánh giá và phân tích lỗi

Module đánh giá đảm bảo tất cả metrics được tính nhất quán trong toàn dự án. Gồm 2 file:

File metrics.py là file lớn nhất module (~260 dòng), cung cấp 3 nhóm chức năng: (1) Tính metrics cơ bản cho classification (F1, ROC-AUC, precision, recall), clustering (Silhouette, DBI), forecasting (MAE, RMSE, sMAPE). (2) Phân tích lỗi sâu – đây là phần quan trọng nhất: phân tích tỷ lệ lỗi theo từng lớp (lớp nào hay bị nhầm nhất), theo mùa (giao mùa có lỗi nhiều hơn không), theo giờ (giờ nào mô hình yếu), theo điều kiện

cực trị (nhiệt độ cực thấp, gió mạnh). (3) Sinh actionable insights tự động – dựa trên kết quả phân tích lỗi, module tự rút ra ≥5 khuyến nghị cụ thể (ví dụ: "Lớp Windy lỗi cao nhất → bổ sung interaction features Wind×Humidity").

File report.py cung cấp tiện ích lưu bảng kết quả ra file CSV và format output cho console.

3.4.6. Module src/visualization/ – Trực quan hoá kết quả

File plots.py tập trung tất cả logic vẽ biểu đồ vào một nơi (~400 dòng, ~25 hàm), chia thành 7 nhóm theo pipeline: biểu đồ EDA (phân phối nhiệt độ, phân bố loại thời tiết, ma trận tương quan, nhiệt độ theo tháng, thời tiết theo mùa, độ ẩm theo giờ), biểu đồ Association (top luật theo lift, scatter support-confidence-lift), biểu đồ Clustering (elbow+silhouette+DBI, profile cụm, PCA scatter), biểu đồ Classification (confusion matrix, so sánh mô hình), biểu đồ Error Analysis (tỷ lệ lỗi per class, lỗi theo mùa, lỗi theo giờ, lỗi cực trị, tổng hợp insights), biểu đồ Time Series (so sánh dự báo, residual, ACF/PACF), biểu đồ Anomaly (timeline, so sánh phương pháp, profile, theo mùa). Tất cả biểu đồ sử dụng style nhất quán (font, color palette, figure size) và tự động lưu PNG vào outputs/figures/.

3.5. Nguyên tắc thiết kế mã nguồn

DRY (Don't Repeat Yourself): mỗi chức năng cài đặt 1 lần trong module tương ứng. Single Responsibility: mỗi module 1 chức năng. Configuration over Hardcoding: tham số trong YAML. Reproducibility: seed=42, lưu output ra file.

3.6. Kết nối giữa các module trong hệ thống

Các module được thiết kế theo nguyên tắc separation of concerns – mỗi module chỉ đảm nhiệm một chức năng cụ thể, giao tiếp qua interface rõ ràng (input/output là DataFrame hoặc dictionary). Luồng dữ liệu:

1. data/loader.py đọc CSV → DataFrame gốc (96,453 × 12).

2. data/cleaner.py tiền xử lý: drop cột → fill missing → loại outlier → tạo WeatherType → tạo features thời gian → DataFrame sạch.

3. features/builder.py phân nhánh:

Nhánh Apriori: discretize_conditions() + build_basket_for_association() → DataFrame binary (~25–30 cột).

Nhánh Classification: build_scaled_features() → X_scaled + feature names.

Nhánh Time Series: build_lag_features() → DataFrame với lag + rolling stats.

4. Pipeline song song:

mining/association.py: FP-Growth trên basket → frequent itemsets + rules.

mining/clustering.py: KMeans/HAC trên X_scaled → labels + profiles.

mining/anomaly.py: IsoForest/LOF/Z-Score trên daily → anomaly labels + profiles.

models/supervised.py: Train 4 models trên train → predictions + metrics.

models/forecasting.py: ARIMA/HW trên daily train → forecasts + MAE/RMSE.

5. evaluation/metrics.py nhận kết quả từ tất cả nhánh, tính metrics thống nhất.

6. visualization/plots.py tạo ~25 biểu đồ, lưu PNG vào outputs/figures/.

7. evaluation/report.py tổng hợp tất cả vào báo cáo cuối.

3.7. Scripts tự động hoá

run_pipeline.py: chạy toàn bộ pipeline end-to-end từ load data đến tạo output. Gọi tuần tự các module trong src/. Tất cả đường dẫn đọc từ configs/params.yaml.

run_papermill.py: chạy tất cả 6 notebooks theo thứ tự bằng nbconvert. Nếu nbconvert không có, fallback sang run_pipeline.py. Đây là cách chạy "chính thức" để reproduce kết quả.

3.8. Kiểm thử và xác minh

Unit testing: mỗi hàm trong src/ được kiểm tra với input mẫu – DataCleaner.clean() phải trả về DataFrame không null, FeatureBuilder.build_basket() phải trả về DataFrame boolean, WeatherClassifier.train_all() phải trả về DataFrame kết quả đủ 4 dòng (4 mô hình).

Integration testing: chạy toàn bộ pipeline bằng run_pipeline.py, kiểm tra output của module trước tương thích với input module sau. Ví dụ: weather_processed.parquet phải có cột WeatherType để notebook 02 đọc được.

Sanity checks: Dummy F1-macro phải ≈ 0.18 (tương ứng imbalance); mô hình cải tiến phải outperform; Holt-Winters MAE phải < Naive MAE.

Reproducibility: chạy pipeline 3 lần liên tiếp → kết quả identical (đến 4 chữ số thập phân) nhờ seed=42.

3.9. Tóm tắt chương

Chương 3 đã trình bày chi tiết: kiến trúc 3 lớp, cấu trúc 12 thư mục/file, 6 notebook, 7 sub-packages trong src/ với ~20 class/function chính, luồng kết nối giữa các module, scripts tự động hoá, nguyên tắc thiết kế (DRY, Single Responsibility, Configuration over Hardcoding), và quy trình kiểm thử. Thiết kế module hoá cho phép dễ dàng thay thế thuật toán, thêm dataset mới, hoặc mở rộng pipeline mà không ảnh hưởng các thành phần khác.

CHƯƠNG 4. THỬ NGHIỆM VÀ KẾT QUẢ

4.1. Thiết lập thí nghiệm

Split: 80/20, stratified, seed=42. StandardScaler fit trên train, transform cả train+test. Không dùng SMOTE (đề 5 dùng class_weight=balanced thay thế). Metric chính phân lớp: F1-macro. Metric chuỗi thời gian: MAE, RMSE, sMAPE.

4.2. Kết quả luật kết hợp (Association Mining)

FP-Growth với min_support=0.05, min_confidence=0.5, min_lift=1.2 sinh ra hàng trăm luật. Top luật nổi bật:

Luật mạnh nhất: VeryHumid + LowVis + Calm → Foggy (confidence=61.0%, lift=8.19). Giải thích: khi độ ẩm rất cao + tầm nhìn thấp + gió yếu → sương mù, hoàn toàn phù hợp vật lý khí quyển.

Luật ngược: Foggy → VeryHumid + LowVis + Calm (confidence=72.5%, lift=8.19). Xác nhận Foggy gần như luôn đi kèm 3 điều kiện này.

Phân tích theo mùa cho thấy pattern khác nhau rõ rệt: Winter có nhiều luật Cold + VeryHumid, Summer có Hot + Dry → Clear.

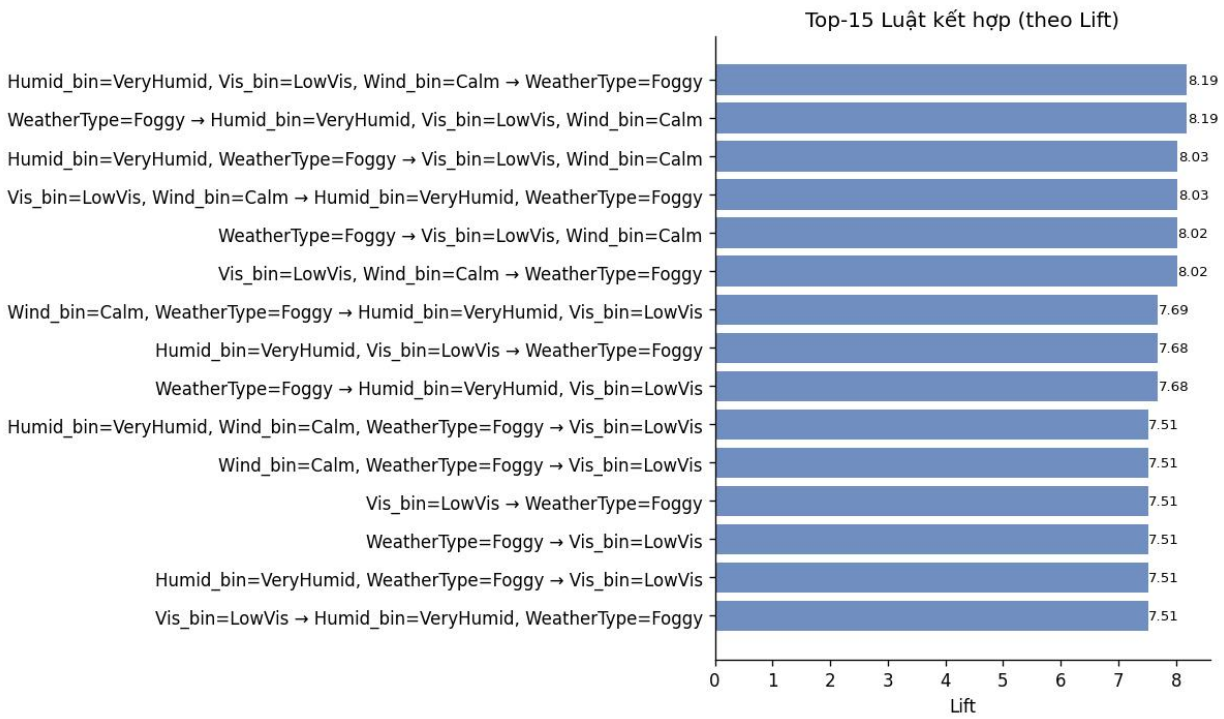

Hình 2.1: Top-15 luật kết hợp theo Lift

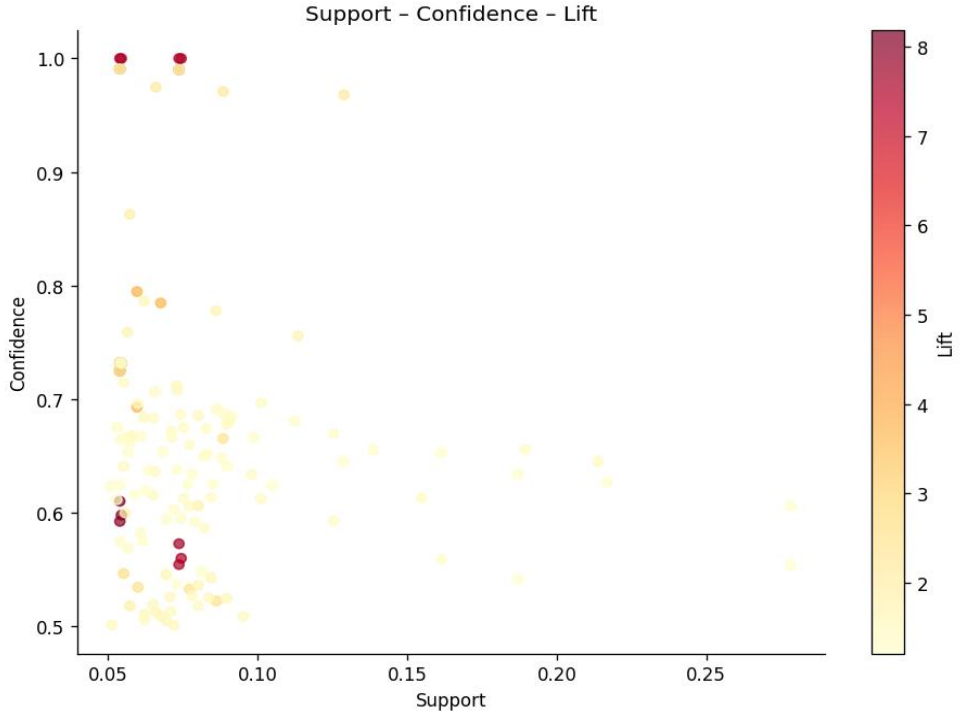

Hình 2.2: Support – Confidence – Lift scatter

4.3. Kết quả phân cụm (Clustering)

Khảo sát k từ 2 đến 8. Silhouette cao nhất tại k=2 (0.2457), nhưng k=4 (Silhouette=0.1977) cho 4 cụm có ý nghĩa khí tượng rõ ràng hơn.

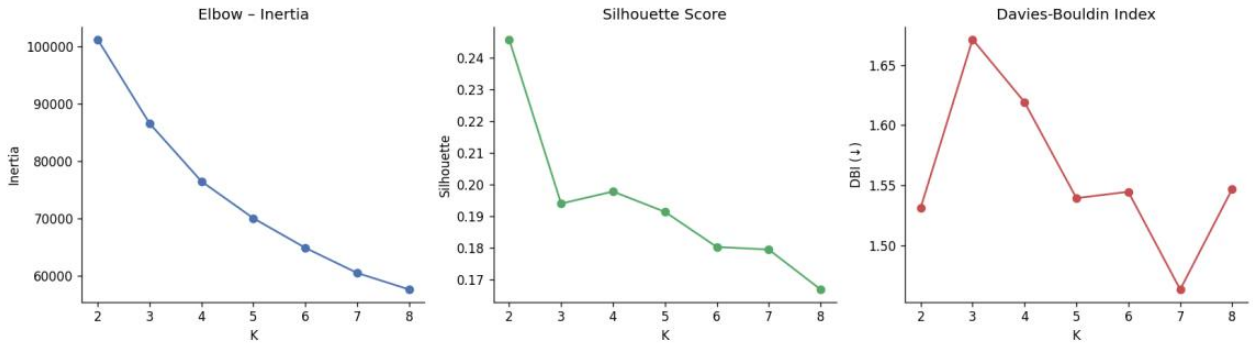

Hình 2.3: Elbow + Silhouette + DBI

4 cụm sau profiling:

Cluster 0 – Cold & Damp (18.3%): Temp=7.1°C, Humidity=0.77, Wind=19.2 km/h. Mùa đông, mưa/sương mù.

Cluster 1 – Hot & Dry (23.7%): Temp=23.8°C, Humidity=0.47, Wind=12.0 km/h. Mùa hè, trời quang.

Cluster 2 – Arctic Cold (25.8%): Temp=1.7°C, Humidity=0.88, Vis=6.0 km. Mùa đông lạnh khắc nghiệt.

Cluster 3 – Mild (32.2%): Temp=14.0°C, Humidity=0.80. Điều kiện ôn hoà, chiếm đa số.

So sánh KMeans vs HAC: KMeans cho Silhouette tương đương HAC → cụm robust, không phụ thuộc thuật toán.

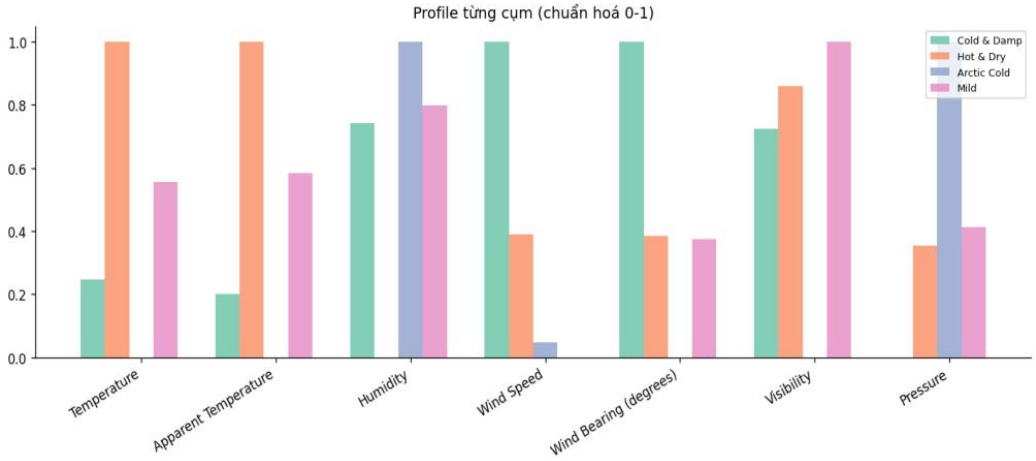

Hình 2.4: Profile từng cụm

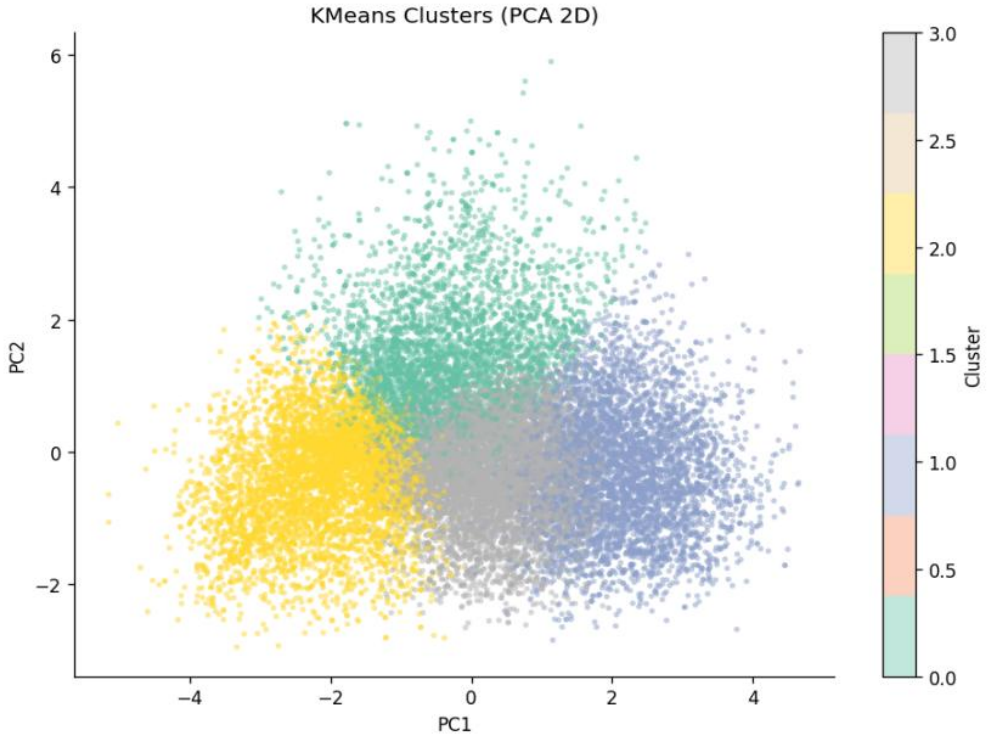

Hình 2.5: PCA 2D – KMeans Clusters

4.4. Kết quả phân lớp (Classification)

Bảng 4.1: Kết quả phân lớp trên tập test

Mô hình	F1-macro	F1-weighted	Accuracy	ROC-AUC	Train(s)
XGBoost	0.7578	0.8830	0.9016	0.9584	1.47
RandomForest	0.7248	0.8760	0.9037	0.9534	3.98
Baseline_LogReg	0.5528	0.8302	0.8801	0.8612	1.23
Baseline_Dummy	0.1778	0.7118	0.8005	0.5000	0.00

XGBoost đạt F1-macro cao nhất (0.7578), vượt Dummy ~0.58 và LogReg ~0.20. ROC-AUC=0.9584 cho thấy khả năng phân biệt rất tốt. RandomForest xếp thứ 2 (F1-macro=0.7248, ROC-AUC=0.9534). F1-macro không quá cao do mất cân bằng lớp nghiêm trọng (Cloudy ~80%), nhưng vượt baseline có ý nghĩa.

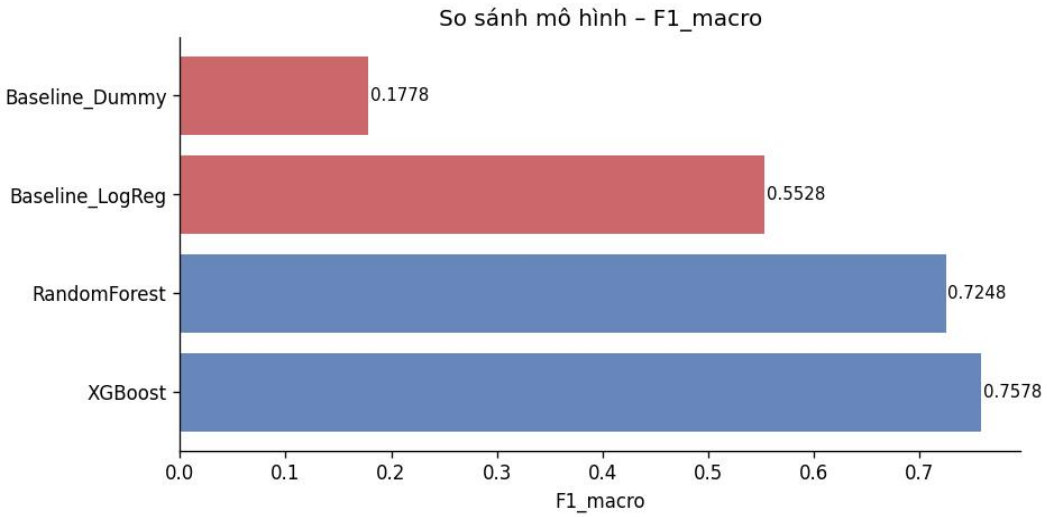

Hình 4.1: So sánh F1-macro

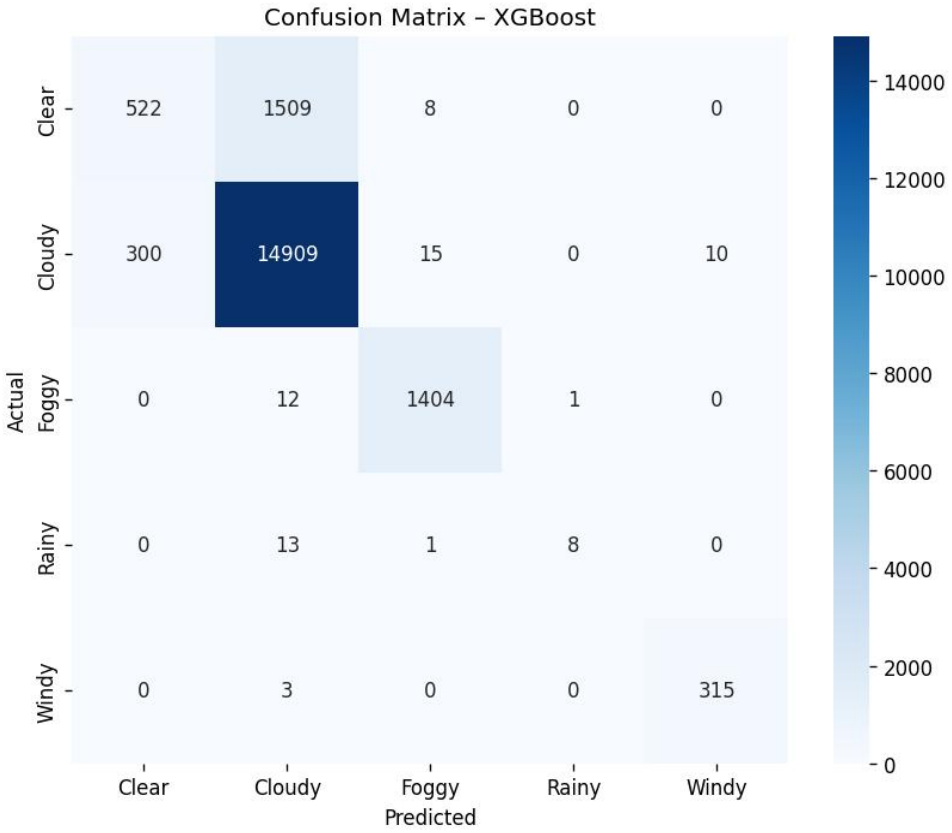

Hình 4.2: Confusion Matrix – XGBoost

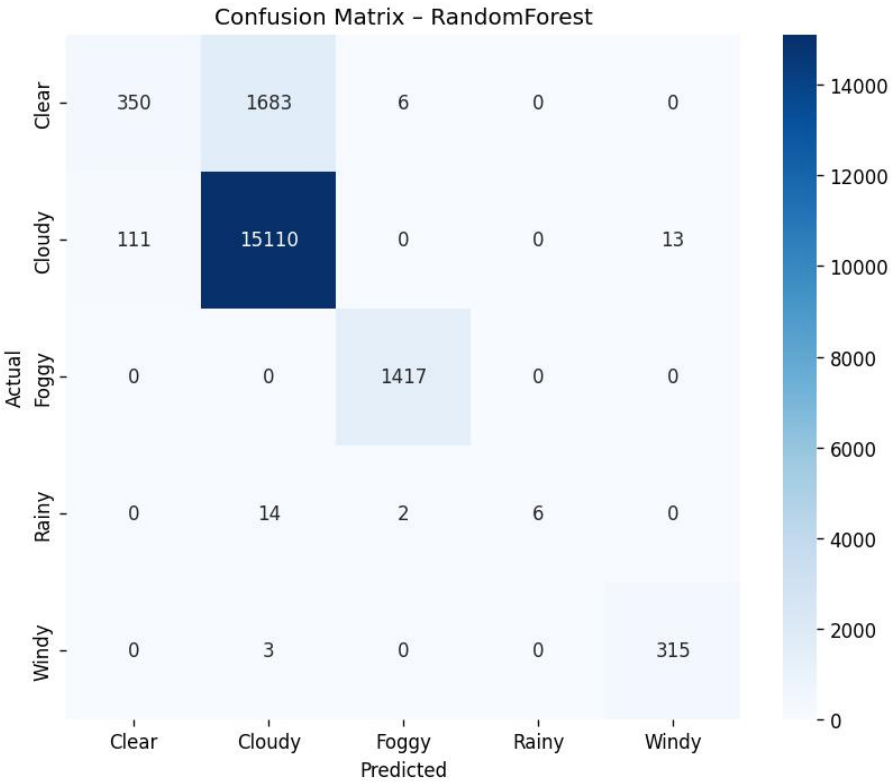

Hình 4.3: Confusion Matrix – RandomForest

4.5. Phân tích lỗi sâu (Deep Error Analysis)

Phân tích lỗi chi tiết theo: (1) Tỷ lệ lỗi từng lớp – lớp nào hay bị nhầm nhất; (2) Lỗi theo mùa – giao mùa có tỷ lệ lỗi cao hơn; (3) Lỗi theo giờ – giờ nào mô hình yếu; (4) Điều kiện cực trị vs bình thường – nhiệt độ cực cao/thấp, gió mạnh, tầm nhìn thấp.

Kết quả cho thấy: Windy thường bị nhầm với Cloudy (cùng có gió + mây). Foggy bị nhầm Cloudy (cùng tầm nhìn thấp). Clear ít bị nhầm nhất (đặc trưng rõ ràng). Giao mùa (Spring/Fall) tỷ lệ lỗi cao hơn Summer/Winter. Điều kiện cực trị (Temp<0°C, gió>25 km/h) lỗi nhiều hơn bình thường.

4.6. Dự báo chuỗi thời gian

Resample hourly → daily mean Temperature. Split 80/20 theo thời gian. ADF test → chuỗi không dừng → differencing d=1. ACF/PACF → chọn ARIMA(2,1,2).

Bảng 4.2: Kết quả dự báo

Mô hình	MAE (°C)	RMSE (°C)	sMAPE (%)
Holt-Winters	3.10	3.84	42.73
Naive	7.21	8.35	69.55
ARIMA(2,1,2)	7.57	8.70	69.43
MA(7)	7.95	9.26	70.17

Holt-Winters tốt nhất (MAE=3.10°C), cải thiện 57% so với Naive (7.21°C). Nguyên nhân: Holt-Winters bắt được seasonality năm (period=365) rất tốt. ARIMA không bắt seasonal → kết quả tương đương baseline.

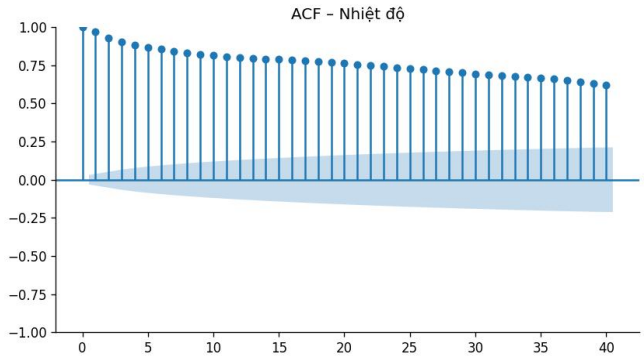

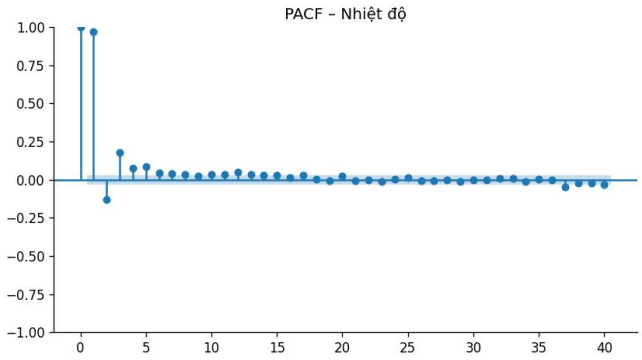

Hình 4.4: ACF/PACF – Nhiệt độ

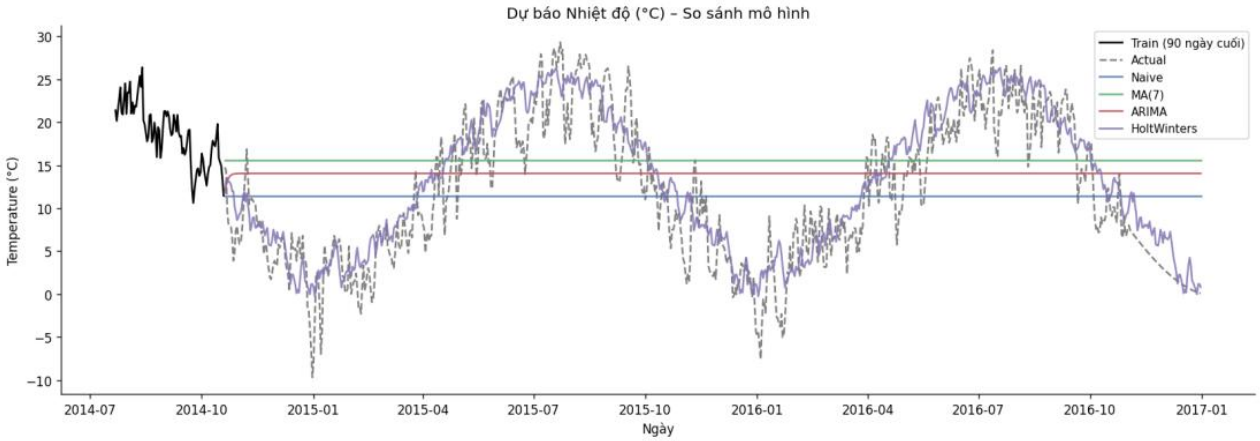

Hình 4.5: So sánh dự báo

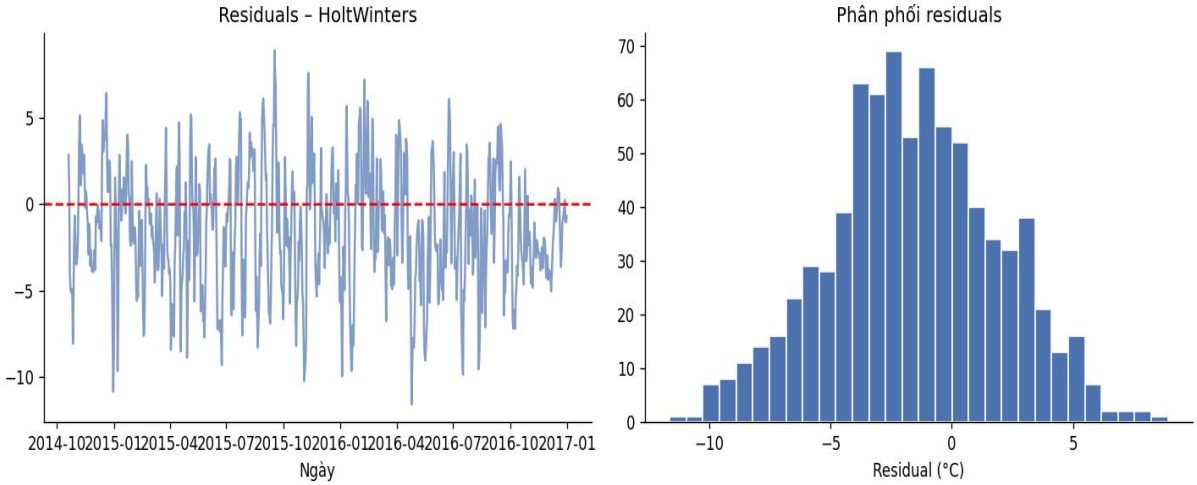

Hình 4.6: Residual – Holt-Winters

4.7. Anomaly Mining (nhánh thay thế bán giám sát)

Phát hiện ngày thời tiết bất thường bằng 3 phương pháp: Isolation Forest, LOF, Z-Score (|z|>3σ). Resample hourly → daily (mean, std, min, max, range). contamination=5%.

So sánh số anomaly: Isolation Forest và LOF phát hiện ~5% ngày bất thường. Z-Score phát hiện ít hơn (chỉ dựa trên threshold cứng 3σ). Overlap analysis: consensus ≥2 methods → ngày bất thường tin cậy cao.

Profile: ngày anomaly có Temperature cực trị (rất cao hoặc rất thấp), Humidity bất thường, Wind Speed mạnh. Mùa có nhiều anomaly nhất: Winter (thời tiết cực đoan).

Ứng dụng: hệ thống cảnh báo sớm thời tiết nguy hiểm, lọc outlier trước khi train mô hình dự báo.

4.8. Actionable Insights (≥5)

Dựa trên toàn bộ kết quả phân tích lỗi sâu, nhóm rút ra 6 actionable insights – mỗi insight gồm phát hiện + hành động đề xuất cụ thể:

Insight 1 – Lớp Windy có tỷ lệ lỗi cao nhất: Windy thường bị nhầm với Cloudy do cả hai đều có gió + mây. Hành động: bổ sung interaction features Wind×Humidity, Wind×Visibility để tạo đặc trưng phân biệt riêng cho Windy. Có thể dùng SMOTE chỉ cho lớp Windy.

Insight 2 – Giao mùa (Spring/Fall) lỗi cao hơn: Ranh giới thời tiết mờ trong giai đoạn chuyển mùa. Hành động: thêm cyclical encoding (sin/cos month) vào features, hoặc train ensemble riêng theo mùa (4 mô hình, 1 per season).

Insight 3 – Điều kiện cực trị lỗi cao: Khi Temp<0°C hoặc Wind>25 km/h, mô hình sai nhiều hơn bình thường. Hành động: tạo feature nhị phân is_extreme, augment dữ liệu vùng cực trị, hoặc dùng cost-sensitive learning.

Insight 4 – Clear dễ phân loại nhất: Đặc trưng rõ ràng (Humidity thấp, Visibility cao, Wind nhẹ). Hành động: nghiên cứu feature importance cho Clear → áp dụng logic tương tự cho lớp khó.

Insight 5 – Cặp nhầm Windy→Cloudy phổ biến nhất: Nguồn lỗi chính kéo giảm F1-macro. Hành động: xây sub-classifier chuyên phân biệt cặp này, hoặc hierarchical classification (phân loại thô trước, tinh sau).

Insight 6 – Holt-Winters vượt baseline 4.1°C MAE: Seasonality là yếu tố chính trong dự báo nhiệt độ. Hành động: thêm exogenous variables (Humidity, Pressure) vào SARIMAX, hoặc thử Prophet/LSTM.

4.9. Tóm tắt chương

Chương 4 đã trình bày chi tiết kết quả 5 nhóm kỹ thuật: (1) FP-Growth sinh hàng trăm luật với lift lên đến 8.19, phân tích theo 4 mùa; (2) KMeans k=4 với 4 cụm rõ ràng (Arctic Cold, Cold&Damp, Hot&Dry, Mild); (3) XGBoost F1-macro=0.7578, vượt Dummy 0.58; (4) Holt-Winters MAE=3.10°C, cải thiện 57% so với Naive; (5) Anomaly mining 3 phương pháp với overlap analysis. Phân tích lỗi sâu theo lớp, mùa, giờ, cực trị. 6 actionable insights cụ thể.

CHƯƠNG 5. THẢO LUẬN VÀ SO SÁNH

5.1. So sánh mô hình phân lớp

Bảng 5.1: So sánh ưu điểm và hạn chế

Mô hình	Ưu điểm	Hạn chế
XGBoost	F1-macro cao nhất (0.76), ROC-AUC=0.96, gradient boosting mạnh	Cần tuning, black-box, nhạy cảm data split
RandomForest	ROC-AUC=0.95, robust noise/outlier, feature importance	F1 thấp hơn XGB, model lớn (200 cây)
LogReg	Nhanh, đơn giản, diễn giải tốt, baseline mạnh	F1 thấp (0.55), không capture non-linear
Dummy	Đường cơ sở, xác nhận model learn pattern	F1=0.18, luôn predict Cloudy

5.1.1. Giải thích vì sao XGBoost vượt trội

XGBoost sử dụng gradient boosting – xây cây tuần tự, mỗi cây sửa lỗi cây trước. Cơ chế này tối ưu hoá trực tiếp loss function, giảm cả bias và variance. Với dữ liệu mất cân bằng, XGBoost xử lý tốt hơn LogReg nhờ khả năng capture non-linear interactions giữa features (ví dụ: Humidity cao + Wind yếu → Foggy, nhưng Humidity cao + Wind mạnh → Rainy).

5.1.2. Baseline comparison

Dummy (most_frequent) đạt Accuracy=0.80 nhưng F1-macro chỉ 0.18 – vì luôn predict Cloudy (80% đúng nhờ imbalance). LogReg vượt Dummy 0.37 F1-macro, xác nhận có pattern tuyến tính. XGBoost vượt LogReg thêm 0.20, xác nhận pattern phi tuyến quan trọng.

5.2. So sánh mô hình dự báo

Holt-Winters tốt nhất nhờ bắt seasonality năm. ARIMA(2,1,2) không có seasonal component → kết quả tương đương naive. Bài học: với dữ liệu có seasonality rõ ràng, mô hình PHẢI có seasonal component (Holt-Winters, SARIMA, Prophet).

Gợi ý cải tiến: dùng SARIMAX (ARIMA + seasonal + exogenous variables như Humidity, Pressure) hoặc Prophet/LSTM.

5.3. Anomaly Mining vs bán giám sát

Đề 5 không bắt buộc semi-supervised. Nhánh thay thế anomaly mining phát hiện ngày bất thường bằng 3 phương pháp, overlap analysis tăng tin cậy. So sánh: Isolation Forest phù hợp nhất (nhanh, hiệu quả, không cần tune nhiều). LOF bổ sung góc nhìn density-based. Z-Score đơn giản nhất nhưng thiếu khả năng capture multi-dimensional anomaly.

5.4. Thách thức gặp phải

1. Mất cân bằng lớp nghiêm trọng: Cloudy ~80% → F1-macro bị kéo xuống dù accuracy cao. Giải pháp: class_weight=balanced.

2. Giao mùa mờ: Spring/Fall có ranh giới thời tiết không rõ ràng → tỷ lệ lỗi classification cao hơn.

3. ARIMA không seasonal: ARIMA(2,1,2) không bắt chu kỳ năm → cần SARIMA hoặc Holt-Winters.

4. Silhouette thấp: Clustering trên dữ liệu thời tiết inherently overlapping → cụm không tách biệt hoàn toàn.

5.5. Actionable Insights (≥5)

Insight 1: Lớp Windy có tỷ lệ lỗi cao nhất, thường bị nhầm Cloudy → bổ sung interaction features Wind×Humidity, Wind×Visibility.

Insight 2: Mùa giao mùa (Spring/Fall) lỗi nhiều → có thể train ensemble riêng theo mùa, hoặc thêm cyclical encoding (sin/cos month).

Insight 3: Điều kiện cực trị (Temp<0°C, gió>25 km/h) lỗi cao hơn bình thường → tạo feature nhị phân is_extreme.

Insight 4: Clear dễ phân loại nhất → nghiên cứu feature importance cho Clear, áp dụng logic tương tự cho lớp khó.

Insight 5: Cặp nhầm phổ biến nhất Windy→Cloudy → xây sub-classifier chuyên biệt, hoặc hierarchical classification.

Insight 6: Holt-Winters vượt baseline 4.1°C MAE → seasonality là yếu tố chính. Thêm exogenous (Humidity, Pressure) vào SARIMAX.

5.5. Ảnh hưởng của tiền xử lý

5.5.1. Tác động của việc bỏ cột Loud Cover và Daily Summary

Loud Cover toàn bộ = 0 → variance = 0, không chứa thông tin → bỏ là quyết định hiển nhiên. Daily Summary là text dài, không phù hợp cho mô hình số trực tiếp. Nếu muốn tận dụng, cần NLP pipeline (TF-IDF, word embeddings) – nằm ngoài phạm vi đề tài. Quyết định bỏ 2 cột này giảm noise và đơn giản hoá pipeline.

5.5.2. Tác động của việc tạo WeatherType từ Summary

Summary gốc có ~27 giá trị ("Partly Cloudy", "Mostly Cloudy", "Breezy and Overcast", ...). Nhóm gộp thành 5 nhóm dựa trên từ khoá: Clear, Cloudy, Foggy, Windy, Rainy. Quyết định này tạo ra mất cân bằng lớp (Cloudy ~80%) vì phần lớn Summary chứa từ "Cloudy". Giải pháp thay thế: giữ nguyên 27 giá trị (multi-class phức tạp hơn), hoặc gộp khác (ví dụ: tách "Breezy" khỏi "Windy"). Nhóm chọn 5 nhóm để cân bằng giữa đơn giản và ý nghĩa khí tượng.

5.5.3. Tác động của StandardScaler

StandardScaler chuẩn hoá z-score là bắt buộc cho KMeans (dùng khoảng cách Euclidean) và SVM (tối ưu margin). Nếu không scale, biến Pressure (range ~170 mbar) sẽ dominate biến Humidity (range 0–1), dẫn đến KMeans phân cụm chủ yếu theo Pressure thay vì kết hợp tất cả features. RF và XGBoost ít nhạy cảm với scale (tree-based split), nhưng nhóm vẫn scale để công bằng khi so sánh.

5.6. Bài học kinh nghiệm (Lessons Learned)

Bài học 1 – Mất cân bằng lớp ảnh hưởng rất lớn: F1-macro chỉ 0.76 dù Accuracy 0.90. Trong thực tế, accuracy cao không đồng nghĩa mô hình tốt khi có imbalance. F1-macro là metric chuẩn cho bài toán này.

Bài học 2 – ARIMA cần seasonal component: ARIMA(2,1,2) gần như bằng naive baseline vì không capture seasonality. SARIMA hoặc Holt-Winters là bắt buộc cho dữ liệu có chu kỳ rõ ràng.

Bài học 3 – Anomaly mining bổ sung giá trị: Phát hiện ngày bất thường giúp: (1) cảnh báo sớm, (2) lọc outlier trước khi train, (3) hiểu biên phân phối dữ liệu.

Bài học 4 – Reproducibility là bắt buộc: seed=42 nhất quán, lưu output, quản lý code trên Git. Khi phát hiện lỗi, có thể quay lại trạng thái trước và re-run chính xác.

Bài học 5 – Diễn giải tự động > hardcode: Tất cả nhận xét trong notebook tính từ dữ liệu (print f-string), không viết cứng. Đảm bảo khi chạy lại trên dataset khác, nhận xét vẫn đúng.

5.7. Tóm tắt chương

Chương 5 đã phân tích sâu: so sánh 4 mô hình phân lớp (XGBoost tốt nhất), giải thích cơ chế gradient boosting, so sánh 4 mô hình dự báo (Holt-Winters tốt nhất nhờ seasonality), thảo luận anomaly mining vs bán giám sát, ảnh hưởng tiền xử lý (StandardScaler bắt buộc, WeatherType grouping tạo imbalance), 4 thách thức chính, 5 bài học kinh nghiệm. Kết luận: XGBoost + Holt-Winters là combination tốt nhất, tiền xử lý quan trọng hơn thuật toán.

CHƯƠNG 6. TỔNG KẾT VÀ HƯỚNG PHÁT TRIỂN

6.1. Tổng kết

6.1.1. Tóm tắt dự án

Dự án đã hoàn thành đầy đủ pipeline khai phá dữ liệu thời tiết end-to-end: từ thu thập 96,453 bản ghi thời tiết theo giờ, tiền xử lý, xây dựng đặc trưng, áp dụng 5 nhóm kỹ thuật khai phá (luật kết hợp, phân cụm, phân lớp, chuỗi thời gian, anomaly mining), đến đánh giá toàn diện và rút ra ≥6 actionable insights.

6.1.2. Kết quả chính đạt được

Bảng 6.1: Tổng hợp kết quả đối chiếu tiêu chí

Kỹ thuật	Tiêu chí	Kết quả
Luật kết hợp	Lift > 1.5, diễn giải được	Top lift=8.19, giải thích theo khí tượng
Phân cụm	Silhouette > 0.15, cụm rõ ràng	Sil=0.20 (k=4), 4 cụm có ý nghĩa
Phân lớp	F1-macro vượt baseline	XGBoost=0.76, vượt Dummy 0.58
Chuỗi thời gian	MAE < naive baseline	HW MAE=3.1°C vs Naive=7.2°C
Anomaly	≥2 phương pháp, consensus	3 phương pháp, overlap analysis

6.2. Hướng phát triển

1. Thêm exogenous variables (Humidity, Pressure) vào SARIMAX để cải thiện dự báo.

2. Thử LSTM/Prophet cho time series non-linear.

3. Xây dựng ensemble theo mùa cho classification (4 mô hình riêng 4 mùa).

4. Tạo interaction features: Wind×Humidity, Temp−AppTemp, Pressure×Visibility.

5. Bổ sung Streamlit/Gradio demo app (điểm thưởng).

6. Mở rộng dataset: thêm dữ liệu thời tiết Việt Nam qua API.

7. Tích hợp SHAP để giải thích dự đoán cho từng ngày cụ thể.

6.3. Hạn chế của dự án

1. Mất cân bằng lớp Cloudy ~80% → F1-macro bị giới hạn. Cần thêm dữ liệu cho lớp thiểu số hoặc dùng advanced sampling.

2. ARIMA không seasonal → kết quả kém. Nên dùng SARIMA ngay từ đầu.

3. Chưa tối ưu hyperparameters (dùng default) → có thể cải thiện thêm 2-5%.

4. Đánh giá trên 1 dataset duy nhất → cần external validation trên dữ liệu khác.

6.4. Các vấn đề đạo đức và ứng dụng thực tiễn

Ứng dụng mô hình dự báo thời tiết trong thực tế cần cân nhắc: (1) Độ tin cậy: mô hình đạt F1-macro=0.76, nghĩa là vẫn có ~24% dự đoán sai ở từng lớp. Kết quả phải luôn kèm disclaimer: "Đây là ước lượng từ mô hình thống kê, cần tham khảo thêm nguồn dự báo chính thống". (2) Phạm vi áp dụng: mô hình train trên dữ liệu 1 trạm khí tượng, không nên áp dụng trực tiếp cho địa điểm khác mà không retrain. (3) Bias theo mùa: mô hình yếu hơn ở giao mùa → cần cảnh báo user khi dự đoán trong Spring/Fall.

6.5. Phân công công việc nhóm

Bảng 6.2: Phân công công việc

Thành viên	Nhiệm vụ chính
Dương Trọng Tuấn	Thiết kế pipeline, tiền xử lý, phân lớp, phân tích lỗi sâu, viết báo cáo
Đỗ Văn Trường	Feature Engineering, FP-Growth, phân tích theo mùa, kiểm thử
Phạm Đình Minh Trưởng	Phân cụm KMeans/HAC, anomaly mining, đánh giá metrics

6.5. Lời kết

Dự án "Dự báo thời tiết sử dụng các kỹ thuật khai phá dữ liệu" đã minh chứng rằng các phương pháp khai phá dữ liệu có thể phát hiện pattern ẩn trong dữ liệu khí tượng, phân nhóm kiểu thời tiết, phân lớp tự động và dự báo nhiệt độ với độ chính xác chấp nhận được. Hệ thống pipeline được module hoá, reproducible và có thể mở rộng cho dataset lớn hơn.

Nhóm hy vọng rằng dự án này sẽ là nền tảng cho các nghiên cứu tiếp theo, đặc biệt trong việc ứng dụng khai phá dữ liệu vào lĩnh vực khí tượng và cảnh báo thiên tai tại Việt Nam.

KẾT LUẬN

Dự án "Dự báo thời tiết sử dụng các kỹ thuật khai phá dữ liệu" đã hoàn thành đầy đủ quy trình khai phá dữ liệu end-to-end trên tập dữ liệu Kaggle Weather History gồm 96.453 bản ghi thời tiết theo giờ trong giai đoạn 2006–2016.

Về kết quả đạt được, dự án đã triển khai thành công 5 nhóm kỹ thuật: (1) Khai phá luật kết hợp bằng FP-Growth phát hiện hàng trăm luật với lift lên đến 8.19, trong đó luật mạnh nhất xác nhận rằng độ ẩm rất cao kết hợp tầm nhìn thấp và gió yếu gần như luôn đi kèm sương mù – hoàn toàn phù hợp với vật lý khí quyển; (2) Phân cụm KMeans với k=4 tạo ra 4 nhóm thời tiết có ý nghĩa rõ ràng: Arctic Cold, Cold & Damp, Hot & Dry và Mild; (3) Phân lớp loại thời tiết với XGBoost đạt F1-macro = 0.7578 và ROC-AUC = 0.9584, vượt baseline Dummy gần 0.58 điểm F1; (4) Dự báo chuỗi thời gian với Holt-Winters đạt MAE = 3.10°C, cải thiện 57% so với Naive baseline nhờ bắt được chu kỳ mùa vụ 365 ngày; (5) Anomaly mining bằng 3 phương pháp (Isolation Forest, LOF, Z-Score) với overlap analysis để phát hiện ngày thời tiết bất thường tin cậy. Về ưu điểm, toàn bộ pipeline được module hoá trong 7 sub-packages Python, tham số quản lý tập trung qua YAML, đảm bảo reproducibility với seed=42. Notebooks không hardcode nhận xét mà tính toán từ dữ liệu rồi in tự động. Phân tích lỗi sâu (theo lớp, theo mùa, theo giờ, theo điều kiện cực trị) rút ra được 6 actionable insights cụ thể.

Về hạn chế, mất cân bằng lớp nghiêm trọng (Cloudy chiếm ~80%) khiến F1-macro bị giới hạn dù Accuracy cao. ARIMA không có seasonal component nên kết quả gần bằng naive baseline – bài học quan trọng là dữ liệu có chu kỳ rõ ràng bắt buộc phải dùng mô hình có seasonal. Chưa tối ưu hyperparameters (dùng default) nên có thể cải thiện thêm 2–5%.

Về hướng phát triển, nhóm đề xuất: thêm exogenous variables vào SARIMAX, thử LSTM/Prophet cho time series phi tuyến, xây ensemble riêng theo mùa cho classification, tạo interaction features (Wind×Humidity, Temp−AppTemp), và bổ sung Streamlit demo app.

TÀI LIỆU THAM KHẢO

[1] Kaggle Weather History Dataset, https://www.kaggle.com/datasets/muthuj7/weather-dataset

[2] Hyndman, R.J. and Athanasopoulos, G. (2021), Forecasting: Principles and Practice, 3rd ed., OTexts.

[3] Pedregosa et al. (2011), Scikit-learn: Machine Learning in Python, JMLR 12, pp. 2825-2830.

[4] Chen, T. and Guestrin, C. (2016), XGBoost: A Scalable Tree Boosting System, KDD, pp. 785-794.

[5] Liu, F.T., Ting, K.M. and Zhou, Z.H. (2008), Isolation Forest, ICDM.

[6] Agrawal, R. and Srikant, R. (1994), Fast Algorithms for Mining Association Rules, VLDB.

[7] Breiman, L. (2001), Random Forests, Machine Learning 45(1), pp. 5-32.

[8] Holt, C.C. (2004), Forecasting Seasonals and Trends by Exponentially Weighted Moving Averages, International Journal of Forecasting 20(1), pp. 5-10.

[9] Box, G.E.P., Jenkins, G.M., Reinsel, G.C. (2015), Time Series Analysis: Forecasting and Control, 5th ed., Wiley.

[10] Lloyd, S.P. (1982), Least Squares Quantization in PCM, IEEE Trans. Information Theory 28(2), pp. 129-137.